CTS 프로젝트 진행 보고서 — DEQ 고정점의 수렴·변별(G1)과 디코더 기여(G2)

기준 시각 **2026-10-14 08:xx KST (G2 4차 확증 + 1단계 R1·R1x·S0·S1 진단 반영)** 작성 **회사 PC Claude Code(CC, 설계·실행·감사 요청)** 독립 감사 **B** 서버 **/home/shoon/cts_e1_s5 (RTX A6000 ×8, 4차는 GPU 5·6·7)** 이전 판 **v3 (10/8 17:3x) 백업 보존**

G1 · DEQ 수렴·변별

사전등록 기준 충족 · 확정

신규 held-out 520 중 517 수렴, 최근접 일치 519/520, 평균 cos 0.569.

G2 1~3차 시도 (10/7~10/11)

기준 미충족 · 확정

1차 게이트 4 −4.83%p, 2차 개발 단계 중단, 3차 게이트 4 +1.20%p(p 0.097).

G2 4차 · M7 수정형 시스템 (10/12)

자체 사전등록 기준 충족

새 1,758문항 1회. 게이트 4 A−E‴ +2.33%p, 95% CI [+0.91, +3.70], p 0.000717. 원래 GOAL의 G2 통과로 보지 않는다.

DEQ 고유 효과 · 문항별 latent 기여

시드 전반에서 확인 안 됨

1단계 R1·R1x(10/13): 같은 조건 A−E는 6쌍 중 A 우위 1·E 우위 3, matched−shuffled 유의는 시드 2047뿐. CTO 기준 (1)·(2) 불충족 → 5차 보류(12절).

---

1. 요약

CTS는 언어모델이 문제를 읽고 만든 잠재 상태를 같은 규칙으로 1,000번 반복해 고정점 z*를 얻는 구조(DEQ)를 검증한다. 두 가지를 묻는다. G1은 "z*가 안정적으로 수렴하고 문항마다 다른가"이고, G2는 "z*를 디코더에 넣으면 수학 문제를 더 잘 푸는가, 그 이득이 반복 전 잠재 z_src보다 큰가"이다. 모든 판정 기준은 결과를 보기 전에 사전등록하고 SHA-256으로 잠갔으며, 독립 감사자 B가 감사했다.

G1은 10/7에 확정됐다. G2는 1~3차 시도에서 모두 게이트 4(DEQ 귀속)를 넘지 못했다. 10/11 진단에서 근본 원인을 찾았다. 잠재를 언어모델에 넣는 투영기가 실제 단어 임베딩보다 25~40배 큰, 모든 문항에 같은 상수 벡터를 넣어 문항 정보가 2~4%로 묻혔다. 그래서 1~3차의 모든 디코더는 잠재를 "고정 soft prompt"로만 썼다(자기 잠재 = 남의 잠재 = 평균 잠재의 NLL).

이 결함을 고친 연결부(PrefixProjectorV2)와 더 강하게 학습한 DEQ 사상으로 4차 방법 M7을 만들었다. 새 사전등록 PREREG_S7_G2v4를 AI 감사 에이전트 B의 감사 3회 뒤 잠그고, 이 프로젝트에서 한 번도 쓰지 않은 1,758문항으로 한 번 평가했다. **결과는 M7 수정형 전체 시스템이 자체 사전등록 기준을 충족한 것이다.** 원래 GOAL의 G2(정본 z*)가 통과된 것으로 보지 않으며, 기존 G2 1~3차는 미통과로 둔다. 게이트 2·3은 A−C +8.08%p(142/0), 게이트 4는 A−E‴ +2.33%p(100/59, 정확

McNemar 단측 p 0.000717, 95% CI [+0.91, +3.70])이다. 4회 시도를 감안한 참고값 p×4 = 0.0029로도 기준 아래다.

해석의 한계도 함께 적는다. (1) A·E는 DEQ 시작점만 다른 조건이 아니다. A에만 보조 손실(λ_ift 0.1)이 들어갔고 decoder와 학습 경로도 달라, A−E 차이를 DEQ 반복 자체의 효과로 보기 어렵다. (2) 보조 게이트 A−B1(다른 문항의 잠재)은 +0.46%p, p 0.26으로 유의하지 않다. 이득이 문항별 잠재 내용에서 왔다는 증거는 정확도 수준에서 아직 없다. (3) A 입력은 GOAL의 "정본 z*"가 아니라 M2′ 고정점에 학습된 한 걸음을 더한 것이다. 따라서 **DEQ 고유 효과와 문항별 latent 기여는 미확인**으로 기록한다.

감사 주체 공개. 이 보고서의 "B"는 사람이 아니다. CC(Claude Code)가 같은 Claude 시스템 안에서 따로 띄운 AI 감사 서브에이전트로, 로컬 파일만 읽고 서버에는 접속하지 않았다. 실행 에이전트 AG(Antigravity)도 AI다. 외부 사람의 독립 검증은 아직 없다.

---

2. 진행률과 일정

목표	진행률	상태
G1 DEQ 수렴·변별		100% · 확정(10/7)
G2 1차 (P6R)		100% · 기준 미충족(확정)
G2 2차 (M2′)		100% · 개발 선택 규칙에서 중단(확증 없음)
G2 3차 (M3)		100% · 기준 미충족(확정)
G2 4차 (M7)		100% · **사전등록 기준 충족**(10/12 05:48)
GOAL G2 인정		Principal 결정 대기(CTS-431)

경과

`10/07 11:2x`	**G1 확정**(RESULT-G1-final.md).
`10/07 23:5x`	G2 1차(P6R, 정지 토큰 결함 수정 재평가) 판정: 게이트 4 −4.83%p로 **기준 미충족**.
`10/08`	원인 진단 1: 정본 주입(문제 토큰 평균 1개)이 고정점에서 문제 정보를 지움 → M2′(주입 = z_src). PREREG_S7_G2v2 잠금(B 감사 4회).
`10/09`	G2 2차 개발 600: A′ 7.50% 대 E′ 7.83% → 선택 규칙 미충족, 새 문항을 열지 않고 중단.
`10/10 23:55`	G2 3차(M3: DEQ 사상과 디코더 공동 학습) 사전등록 PREREG_S7_G2v3_1 잠금(AG가 감사 없이 잠근 원본을 CC가 멈추고 사후 감사 AUDIT-P013 → 개정).

10/11 08:23	G2 3차 확증(새 1,000문항): 게이트 4 +1.20%p, p 0.0973 → **기준 미충족**.
10/11 08:5x ~ 13:2x	원인 진단 2(개발 600만 사용): 잠재 내용 미사용 확인 → 짝 맞춤 정상 → 투영기 출력 크기 결함 발견 → 양성 대조로 "DEQ 잠재에 쓸 내용 부족" 확인 → Φ_θ 강학습에서 첫 양의 신호.
10/11 13:23 ~ 16:27	M7 복제(2시드) 후 개발 600 정확도 1회: A 7.83% 대 E‴ 4.83%, +3.00%p, p 0.0137(판정 아님).
10/11 16:3x ~ 17:15	새 문항 1,758 선택·id 전수 검사(적중 0), PREREG_S7_G2v4 작성 → B 감사 FIX 5건 → 재FIX 2건 → **PASS·잠금**.
10/11 17:18	4차 확증 착수(GPU 5·6·7). z*′ 1,758문항 계산 21:04 완료.
10/11 21:04	서버 /home 디스크 100%로 병합 단계 저장 실패(채점 전). 사전등록 §5 재개 규칙·B 사전 확인으로 21:25 재개(큰 텐서는 /tmp, 결함 파일은 삭제 없이 이동).
10/12 05:48	생성 7,032건 완료·채점 → **G2v4 사전등록 기준 충족**.

3. 판정 기준 (결과 보기 전에 잠금)

목표	기준	사전등록 · SHA-256
G1	신규 520 수렴 ≥90%, 문항 간 평균 cos ≤0.75, 최근접 일치 ≥99%, 앵커 재현	`PREREG_S7_DEQ_v1.3/1.4` · 254beb6f… · 04112522…
G2 (공통)	게이트 2(A−C ≥ −2%p) ∧ 게이트 3(A−C: 정확 McNemar 단측 p<0.025 ∧ 부트스트랩 95% 하한>0) ∧ 게이트 4(A−E: 같은 기준), strict 채점. 게이트 1(A−B1)은 보조	`shared/GOAL.md`
G2 1차	위 기준, held-out 600	`PREREG_S7_D_v3_8` · 58b4a7f3…
G2 2차	개발 선택 규칙(A′−E′ > 0 ∧ A′−C > 0) → 새 1,000	`PREREG_S7_G2v2` · 4ea1d966…
G2 3차	개발 선택 규칙 → 새 1,000, p×3 참고	`PREREG_S7_G2v3_1` · 3d1a6ee0…
G2 4차	새 1,758 한 번, 판정 키 `gates.Gate_{2,3,4}.strict`, p×4 참고	`PREREG_S7_G2v4` · 5923fef7…

채점기 `scripts/s5_eval_grader_v2.py`(90cc93e4…), 채점 스크립트 `s7_eval_score_p6_v36.py`(547e1d91…), 부트스트랩 10,000회·시드 2026은 모든 시도에서 같다.

4. G1 결과 — DEQ 수렴·변별 (확정)

항목	값	기준	판정
①-b 확증 · 신규 520 수렴	517/520 (99.4%)	≥90%	충족
①-b 보조 · 600	596/600	≥90%	충족
①-a 보조 · train 1,000	991/1000	≥95%	충족
문항 간 평균 cos	0.569	≤0.75	충족
최근접 일치율	519/520	≥515	충족
앵커 재현	20/20 cos≥0.99999997	cos≥0.9999	충족

G1은 사전등록한 최저점 규칙으로 충족했다(1,000번째 최종점 기준 456/520). G1 충족은 "고정점이 안정되고 문항마다 다르다"까지만 뜻한다.

5. G2 시도별 결과

시도	방법	문항	A	E	C	게이트 4 (A−E)	판정
1차 P6R	정본 z* + v3.6 투영기	600	1.67%	6.50%	0.33%	-4.83%p, 7/36	미충족
2차 M2′	주입 = z_src	개발 600	7.50%	7.83%	0.33%	-0.33%p	개발 중단
3차 M3	DEQ 사상 + 디코더 공동 학습	새 1,000	6.50%	5.30%	0.10%	+1.20%p, 42/30, p 0.0973	미충족

4차 M7	**V2 연결부 + Φ_θ 강학습 + 글 가리기**	새 1,758	8.08%	5.75%	0.00%	+2.33%p, 100/59, p 0.000717	충족

정확도는 strict(\boxed{} 정답) 기준이다. 1·3·4차의 게이트 2·3은 모두 충족했다(1차 A–C +1.33%p p 0.0193, 3차 +6.40%p, 4차 +8.08%p).

---

6. 근본 원인 진단 (10/11, 개발 600만 사용)

진단은 이미 열람한 개발 600과 학습 문항만 썼다. 새 문항은 열지 않았다. 지표는 정답 해설의 teacher-forced 평균 NLL이다. 전문: `shared/reports/DIAG-G2v4-rootcause-20261011.md`.

6-1. 디코더는 잠재의 문항 내용을 쓰지 않았다

디코더	자기 잠재	다음 문항 잠재	평균 잠재(상수)
3차 A	0.8782	0.8777	0.8767
3차 E‴	0.8933	0.8941	0.8933

글을 가리고 학습(M4), 처음부터 글 없이 학습(용량 파일럿), 언어모델에 LoRA를 붙여도 같았다. 학습 문항에서도 같았다. 데이터 짝짓기는 정상이었다(정본 로더 재계산 cos 1.0, 검색 20/20).

6-2. 원인: 투영기 출력의 크기와 상수 지배

단계	문항 고유 에너지 비율	칸당 norm
입력 z_src	0.576	288.7
3차 E 디코더 · `w_proj` 뒤	0.101	141
3차 E 디코더 · 어댑터 뒤(LM 입력)	0.027	1,258
참고: 실제 단어 임베딩	–	50.5

64칸 자리는 LM이 읽을 수 있다. 글 없이 그 자리에 자기 문제의 단어 임베딩을 넣으면 NLL 2.711 → 2.376, 다른 문제는 2.633.

6-3. 잠재 내용과 해결 실마리

- 크기를 맞춘 V2 투영기로도 DEQ·z_src 잠재의 문항 내용 사용은 없었다(z ≤ 1.2). 잠재를 단어로 풀면 무의미한 문자열이다. 문제 글 은닉 상태를 잠재로 쓴 양성 대조는 같은 경로로 정보가 약하게 전달됐다(z 2.7). 즉 **DEQ 잠재 자체에 LM이 쓸 내용이 거의 없었다.**
- DEQ 사상 Φ_θ(문제 글을 attention으로 읽음)를 10배 학습률로 학습하자, DEQ 고정점에서 출발한 A 잠재만 문항 특이성이 생겼다(z 2.7, 복제 z 4.4). z_src 출발 E는 z 0.6. A−E NLL −0.0236(z −7.2).

---

7. 4차 방법 M7

구성	내용
고정점	M2′(주입 = z_src, α = g_0 = 0.25, 1,000번 반복)로 학습 전 사상 Φ_0에서 계산한 $z^{*\prime}_0$
학습된 한 걸음	$T_\theta(z) = (1-\alpha)z + \alpha[\Phi_\theta(z) + g_0 \cdot z_{src}]$, Φ_θ = LoRA r8 q·v·o + routing_proj + γ
연결부	PrefixProjectorV2: 학습 시작 잠재의 칸별 평균을 빼고 RMS 정규화 → `w_proj`(항등 초기화) → MLP 어댑터 → RMS 정규화 × 실제 단어 RMS(0.9981)
학습	3,000단계, 배치 4, 학습 993문항, lr 투영기 1e-4·어댑터 3e-4·DEQ 3e-4, 글 가리기 0.5, 시드 2047. λ_ift A 0.1 · E 0. A·E 모두 993/993, 가리기 6,061회로 같음
조건	A = decoder_M7A + $T_{\theta,A}(z^{*\prime}_0)$ · E‴ = decoder_M7E + $T_{\theta,E}(z_{src})$ · C = 순정 Gemma 글만 · B1 = A 디코더 + 한 칸 민 A 잠재

---

8. 4차 확증 결과 (새 1,758문항, 1회)

조건	strict	lenient
A · M2′ 고정점 → 학습된 한 걸음 + V2	**8.08%**	**12.91%**
B1 · A 디코더 + 다른 문항 A 잠재 (보조)	7.62%	12.86%
E‴ · z_src → 학습된 한 걸음 + V2	5.75%	11.60%
C · 순정 Gemma, 글만	0.00%	8.02%

게이트	비교	Δ	95% CI	b/c	p	p×4	결과
2 바닥선	A − C ≥ −2%p	+8.08%p	[+6.83, +9.33]	142/0	–	–	충족

3 기여	A − C	+8.08%p	[+6.83, +9.33]	142/0	<1e-6	<4e-6	충족
4 DEQ 귀속	**A − E‴**	**+2.33%p**	**[+0.91, +3.70]**	**100/59**	**0.000717**	**0.0029**	**충족**
1 보조	A − B1	+0.46%p	[-0.80, +1.65]	64/56	0.2615	−	유의하지 않음

원자료 `shared/reports/g2v4fresh/gate_table.json`(ea120d95…). CC가 b = 100, c = 59의 정확 이항 단측 p를 따로 계산해 0.000717로 일치를 확인했다. 판정 문서 `shared/reports/RESULT-G2v4-confirm.md`. 보고 항목(판정 미사용): 한 걸음 상대 이동 중앙값 A 0.1266 · E 0.1058.

---

9. 실행 경과와 사고 처리

- 착수 10/11 17:18:14. 사전 점검에서 SHA 21개 일치, 출력 없음, GPU 5·6·7 비어 있음.
- z*′ 1,758문항: 21:00/21:00/21:04 완료, 1,758/1,758이 r_1000 < 1e-2.
- **21:04 서버 /home 디스크 100%(여유 0)로 병합 파일 저장 실패.** 채점 전이라 결과는 없었다. 사전등록 §5의 재개 규칙에 따라 재개 스크립트를 만들고 B의 사전 확인("실행 가능")을 받았다.
  - 큰 텐서(약 6GB)는 루트 디스크 `/tmp/cts_g2v4_shoon`(권한 700)에 썼다.
  - 잘린 결함 파일(2.72GB)은 지우지 않고 그 폴더로 옮겨 /home에 생성 결과용 공간을 확보했다.
  - 실패한 단계부터 같은 명령으로 실행했고 이어 쓰기는 없었다. 생성·채점 명령, 문항, 체크포인트는 바뀌지 않았다.
- 재개 21:25 → 잠재 LOAD-GUARD 436·0 ×2, PROJ-V2 확인 9개 로그 → 병합 4조건 각 1,758행·오류 0 → 채점 05:48:20.

---

10. 품질 관리 — 감사 이력

> **감사자 B는 AI다.** AUDIT-P011~P014의 감사자 B는 CC가 같은 Claude 시스템 안에서 띄운 별도 AI 서브에이전트다(로컬 파일만 읽음, 서버 접속 0). 같은 실행 체계 안의 감사이므로 외부 사람의 독립 검증과 같지 않다.

감사	대상	결과
AUDIT-P011	PREREG_S7_D_v3_8 (1차)	FIX 12 → 3 → PASS

AUDIT-P012	PREREG_S7_G2v2 (2차)	FIX 13 → 5 → 4 → PASS. 새 문항 목록과 겹치는 서버 파일 35개 발견 → 보수 제외
AUDIT-P013	PREREG_S7_G2v3 (3차, 사후 감사)	AG가 감사 없이 잠금 → CC가 확증을 멈춤. FIX 8 → 4 → PASS. 개발 A 80문항이 옛 z*를 받은 키 결함을 찾아 다시 함
AUDIT-P014	PREREG_S7_G2v4 (4차)	FIX 5(원시 근거·Ez 공개·공정성·GOAL·스크립트 가드) → 재FIX 2 → PASS. 재개 1 사전 확인 "실행 가능"

새 문항 1,758의 사용 흔적은 서버의 `.jsonl` 72개 id와 `.pt` 374개 키를 모두 대조해 0건이었다. 같은 검사기로 3차 사용 목록을 검사하면 23개 파일에서 적중해, 검사기가 실제로 흔적을 잡는다는 것도 확인했다.

---

11. 한계와 해석

1. **λ_ift 혼입.** 게이트 4는 "DEQ 시작점 때문"과 "A만 받은 IFT 보조 손실 때문"을 가를 수 없다. 개발 진단에서 같은 A 디코더에 입력만 T_θ,A(z_src)로 바꾸면 NLL 차이가 0.0011뿐이었다. A–E 차이의 대부분은 학습 경로에서 온다.
2. **문항 내용 기여 미확인.** 보조 게이트 A–B1 +0.46%p(p 0.26). 정확도 수준에서는 다른 문항의 A 잠재로도 비슷하게 맞힌다.
3. **GOAL 표현과의 차이.** A 입력은 GOAL의 "정본 z*"가 아니다(z*'₀에서 중앙값 12.7% 이동). 평가도 GOAL의 "held-out 600"이 아니라 새 1,758문항이다.
4. **다중 시도.** 4차 시도다. p×4 = 0.0029.
5. **설계 선택.** M7 설정은 개발 600의 NLL 진단을 여러 번 보고 골랐다(선택 편향 가능). 정확도는 개발에서 한 번만 봤고, 판정은 새 문항으로만 했다.
6. **단일 시드·로더.** A·E 디코더는 시드 하나다. 고정점은 정본 로더로, 학습된 한 걸음은 학습 스크립트의 로더로 계산했다(같은 문항 z_src cos 0.70~0.91, A·E 동일 조건).
7. **절대 정확도.** 가장 높은 A도 strict 8.08%다. 이 평가는 상대 비교(게이트)를 위한 것이며 실용 수준의 성능 주장이 아니다.

---

12. 1단계 견고성 실험 R1·R1x (10/12~13, 개발 600, 판정 아님)

CTO 의견(CTS-432)에 따라 {A, E} × {보조 손실 λ_ift 0, 0.1} × 시드 3(2047·2049·2050)을 같은 레시피로 학습해 원인을 분리했다. 새 문항은 쓰지 않았다. 해석 규칙은 결과 전에 고정했다 (`shared/proposals/R1_ROBUSTNESS_PLAN_20261012.md`). 전문: `shared/reports/RESULT-R1-robustness-20261012.md`.

12-1. 같은 학습 조건의 A – E (strict)

λ_ift	시드 2047	시드 2049	시드 2050	평균
0	+4.83%p (p 0.0002)	-6.00%p	-0.50%p	-0.56%p
0.1	-1.83%p	-3.17%p	-6.33%p	-3.78%p

시드 평균 strict: A λ0 5.72%·λ0.1 4.11%, E λ0 6.28%·λ0.1 7.89%. A 일부 시드는 답 형식(\boxed)을 거의 내지 못해 정확도가 0.17%·1.83%로 무너졌다.

12-2. 같은 A 디코더에서 matched z* − shuffled z* (strict)

디코더	Δ	95% CI	b/c	p
Ah (λ0.1, 2047, 4차 모델)	+2.33%p	[+0.33, +4.33]	25/11	0.014
R1A0s47 (λ0, 2047)	+3.50%p	[+1.50, +5.50]	29/8	0.0004
R1A0s49 (λ0, 2049)	+0.17%p	[-1.33, +1.67]	10/9	0.50
R1A0s50 (λ0, 2050)	+0.83%p	[-1.33, +3.00]	25/20	0.28
R1A1s49 (λ0.1, 2049)	+1.67%p	[-0.33, +3.67]	23/13	0.066
R1A1s50 (λ0.1, 2050)	+0.17%p	[0.00, +0.50]	1/0	0.50

NLL로 보면 잠재 주입 효과(no-injection 1.918 → 디코더 0.83~0.93)는 대부분 문항 무관이며, matched−shuffled 차이는 0.002~0.005로 A·E 모두에 비슷하게 있다.

12-3. CTO 기준 판단

기준	결과	판단
(1) 같은 학습 조건에서 matched z* > matched z_src, 시드 전반 일관	6쌍 중 A 유의 우위 1, E 유의 우위 3, 시드 평균 E 우위	불충족
(2) 같은 디코더에서 matched z* > shuffled z*, 유의	6개 중 유의 2(모두 시드 2047)	시드 전반 불충족

> **읽은 것.** 4차 확증의 게이트 4 충족은 사전등록에 고정된 모델 쌍(Ah·Eh, 시드 2047)에 대해 절차상 유효하다. 그러나 R1은 그 이득이 M7 방법의 일반적 성질이 아니라 특정 시드·학습 경로의 결과일 가능성이 크다는 것을 보여 준다. 두 기준 모두 시드 전반에서 확인되지 않았으므로, CTO 지침대로 5차 확증과 새 test 데이터 개봉은 하지 않는다.

12-4. 시드 2047 원인 분석과 S0 (10/13, 새 학습·새 생성 0)

CTO 답신(CTS-433)에 따라 기존 체크포인트·로그·생성만으로 분석했다. 전문: `shared/reports/DIAG-seed2047-forensic-20261013.md`.

- 모델 12개에서 strict 정확도와 \boxed 비율의 상관 0.94, 투영기 출력의 문항 고유 비율과의 상관 −0.85. 잘 푸는 디코더일수록 문항 정보를 지워 공통 prefix만 넘겼다.
- 시드 2047의 A 디코더 두 개는 문항 변동을 거의 지웠고(0.46%·0.17%), 4차에서 짝지은 Eh는 E 중 유일하게 변동을 크게 통과시켜(23.8%) 형식 준수가 가장 낮았다.

4차 새 1,758문항 A − E‴ (같은 원자료)	Δ	b/c	p
strict 전체 (사전등록 판정 지표)	+2.33%p	100/59	0.0007
lenient 전체	+1.31%p	109/86	0.058
둘 다 \boxed를 낸 332문항 · strict	+3.01%p	37/27	0.130
\boxed 비율	A 43.1% · E‴ 31.4%		
형식을 지킨 답 안의 정답률	A 18.8% · E‴ 18.3% · B1 18.1%		

> **읽은 것.** 4차 게이트 4의 차이는 대부분 답 형식(\boxed) 준수 차이에서 왔다. 형식을 지킨 답 안에서는 A·E‴·B1의 정답률이 거의 같고, 둘 다 형식을 지킨 문항에 한정하면 A − E와 matched − shuffled가 개발·4차 어디에서도 유의하지 않다. DEQ 잠재의 내용 기여와 문항별 기여는 확인되지 않았다. 4차 판정 자체(사전등록 strict 지표)는 바꾸지 않는다.

12-5. S1 형식 지시 고정 실험 (10/13~14, 개발 600, 판정 아님)

모든 조건의 프롬프트에 "Put your final answer within \boxed{}."를 고정하고 {A, E} × λ_ift 0 × 시드 3으로 다시 학습했다(사용자 지시로 착수). 전문: `shared/reports/RESULT-S1-format-fixed-20261014.md`.

시드	A strict	E strict	A − E (b/c)	A matched − shuffled (p)
2047	4.83%	8.17%	-3.33%p (18/38)	+0.50%p (0.375)
2049	7.00%	8.67%	-1.67%p (27/37)	+1.17%p (0.205)
2050	3.83%	6.33%	-2.50%p (15/30)	+1.00%p (0.203)

> **읽은 것.** 기준 (1)·(2) 모두 불충족. 형식을 글에 고정해도 A의 \boxed 비율(26~44%)이 E(42~54%)보다 낮고, 형식을 지킨 답 안의 정답률은 A·E가 같다(약 15~16%). 형식 혼입을 줄인 조건에서도 DEQ 시작점이 z_src보다 낫다는 증거는 없고 3시드 모두 E가 낫다.

S1 같은 형식 조건	strict	lenient	\boxed	형식 지킨 답 안 정답률
C · 순정 Gemma (잠재·디코더 없음)	**12.83%**	**15.67%**	**35.5%**	**36.2%**
A 디코더 3개	3.83~7.00%	6.17~10.00%	26.3~43.5%	14.6~16.1%
E 디코더 3개	6.33~8.67%	10.17~11.17%	42.3~54.0%	15.0~16.0%

> **추가로 읽은 것.** 형식 지시만 주면 순정 모델(C)이 잠재+디코더 조건 모두보다 잘 푼다. 1~4차의 게이트 2·3(A − C +6~+8%p)은 C가 형식 지시 없이 \boxed를 거의 쓰지 않은 데서 왔다(4차 C \boxed 4/1,758). 같은 형식 조건에서는 잠재 prefix가 풀이를 오히려 방해한다.

12-6. S1을 CTO 지표로 다시 분석 (10/14, 새 학습·생성 0)

CTO 지침(CTS-434: lenient 주 지표, \boxed 비율 선확인, 시드 반복을 반영한 문항 단위 cluster bootstrap, 세 시드 종합 matched−shuffled CI 하한 > 0)은 S1 종료 뒤 전달되어, S1은 원래 계획 기준으로 실행됐다. 아래는 기존 문항별 채점을 CTO 지표로 다시 계산한 것이다(bootstrap 10,000회).

점검	결과	판단
⓪ 모든 조건 \boxed 비율이 충분히 높고 비슷한가	C 35.5%, A 26~44%, E 42~54%, shuffled 26~53%	불충족
① A − E · lenient (주)	-2.83%p, 95% CI [-4.50, -1.22]	E 유의 우위
① A − E · strict (보조)	-2.50%p, CI [-4.06, -1.00]	같은 방향
② A matched − shuffled · lenient (핵심)	**+1.17%p, CI [-0.17, +2.50]**	불충족 (하한 < 0)
② A matched − shuffled · strict (보조)	+0.89%p, CI [-0.33, +2.11]	불충족
참고 · E matched − shuffled · lenient	-0.89%p, CI [-2.33, +0.56]	차이 없음

전문: shared/reports/RESULT-S1-format-fixed-20261014.md §7, 원자료 shared/reports/s1/s1_items.json. CTO 지침대로 S2는 바로 시작하지 않고 결과와 진단부터 공유한다.

13. 다음 단계 설계안 (검토용 · 승인 전 실행 없음)

CTO 의견(CTS-433)에 따라 A 안정화·새 학습 목표·IFT를 동시에 진행하지 않고, 아래 설계안을 먼저 공유한다. S0(새 학습 없음)은 12-4절에서 완료했다. S0 결과 형식(`\boxed`) 준수가 가장 큰 혼입 요인이므로 S1을 먼저 제안한다.

안	내용	새 학습	무엇을 확인하나	상태
S0	기존 생성 재채점: lenient, 형식을 지킨 답 안의 정답률, 둘 다 형식을 지킨 문항 한정 비교	없음	형식을 빼면 내용 효과가 남는가	완료
S1	형식 지시를 모든 조건의 프롬프트에 고정해, 형식은 글이 담당하고 잠재는 내용만 담당	있음	형식 혼입을 없앤 뒤 A > E, matched > shuffled 가 생기는가	완료 · 두 기준 불충족 (12-5)
S2	통로 용량 점검: 정답 정보가 든 오라클 잠재로 같은 경로를 학습	있음	이 연결부가 문항 내용을 정답률로 바꿀 수 있는가	S1 뒤 검토
S3	두 채널 분리: 공통 soft prompt(형식) + 0에서 시작하는 게이트 잔차(문항 내용)	있음	내용이 형식을 깨지 않고 더해지는가	S1·S2 뒤 검토

13-1. S1 상세 설계

항목	내용
바꾸는 것 한 가지	학습과 평가의 프롬프트에, 모든 조건(A·E·B1·C)에서 같은 형식 지시 문장을 문제 글 뒤에 고정한다. 예: "Put your final answer within \boxed{}." 글 가리기로 문제 글을 빼는 학습 단계에서도 이 문장은 남긴다.
그대로 두는 것	V2 투영기, 학습 문항 993, 3,000단계, 배치 4, lr(1e-4 / 3e-4 / 3e-4), 글 가리기 0.5, 백본 로더, 채점기(90cc93e4…). 기존 스크립트는 바꾸지 않고 새 판(학습·생성 각 1개)을 만들어 diff를 공개한다.
설계	{A, E} × λ_ift 0(보조 손실 없음, 대칭) × 시드 3(2047·2049·2050) = 학습 6개. 같은 decoder로 matched·shuffled·다른 시작점·평균·zero·no-injection 비교(NLL), matched·shuffled 정확도(생성).
데이터	학습 993, 평가 개발 600만. 새 test 데이터는 열지 않는다.

미리 정할 판단 기준	(1) 같은 학습 조건 A – E(matched z* 대 matched z_src)가 3시드 모두 같은 방향이고 3시드 합산 McNemar가 유의, (2) 같은 A decoder에서 matched – shuffled가 3시드 중 2개 이상에서 유의. 보고: 시드별·평균, strict·lenient, `\boxed` 비율, 형식을 지킨 답 안의 정답률, NLL, 생성 길이.
성공 조건 해석	두 기준을 모두 넘으면 S1 구조로 새 데이터 5차 확증을 검토한다. 넘지 못하면 S2(통로 용량)로 원인이 연결부인지 잠재 내용인지 가린다.
예상 비용	GPU 5·6·7에서 학습 약 3시간 + 평가 약 5~6시간, 총 9시간 안팎
위험	형식 지시가 순정 모델(C)의 정답률도 함께 올린다. 이는 의도된 것이다(공정 비교). 게이트 2·3의 크기는 줄어들 수 있다.

---

14. 결정 요청과 다음 단계

> **CTO 의견에 따른 진행 원칙 (10/12, CTS-432).** 1단계 {A, E} × {보조 손실 유/무} × 시드 3은 원인 분리용 개발·진단 실험으로 진행하며 설정을 바꾸지 않고 코드·체크포인트·원시 로그를 보존한다. 같은 디코더에서 matched z*·shuffled z*·matched z_src·평균 z·zero/no-injection을 비교한다. 다음 단계로 넘어가는 기준은 (1) 같은 학습 조건에서 matched z*가 matched z_src보다 일관되게 높고, (2) 같은 디코더에서 matched z*가 shuffled z*보다 유의하게 높은 것이다. 두 조건이 개발 데이터와 여러 시드에서 모두 확인될 때만 새 데이터 5차 확증을 검토하며, 그전에는 새 test 데이터를 열지 않는다. IFT 실험과 데이터 확대는 5차 이후로 둔다.

항목	내용	결정 주체
CTS-431	개선판(M7) 통과를 GOAL의 G2 통과로 인정할지	Principal
ESC-0009	서버 /home 100%(3.6T 중 shoon 892G, 다른 사용자 1.3T, 권한 밖 약 1.2T). 재현용 텐서가 휘발성 /tmp에 있음	Principal·서버 관리자
ESC-0007	GPU 2 하드웨어 오류, GPU 0/1/3 감속	Principal
권고 후속	λ_ift 대칭 재현(A·E 같은 보조 손실), 다중 시드, 정본 로더 통일, 문항 내용 기여(A–B1) 강화. 새 데이터 출처가 필요하다(현 5,000문항 풀은 미열람 문항이 남지 않음)	Principal 승인 후 CC

부록 A. 검증 파일과 SHA-256

A-1. 사전등록·감사

파일	SHA-256
shared/prereg/PREREG_S7_G2v4.md (잠금본)	5923fef7e82afdd74b7c471e6f98da4d724ef9d04c20e782b1227fe1d7c5a2ce
PREREG_S7_G2v4 rev3 (B PASS 대상)	82f969788cf59d95aee06ee854a294599b273e2702fc1fcd6d10eb542ed01d80
PREREG_S7_G2v3_1.md (3차)	3d1a6ee0292b58fcab514ec2b71588dc78a277f6c464e61739ebb4ac96573daa
PREREG_S7_G2v2.md (2차)	4ea1d9663c3a029a382bd503a9628992b600992160cfbf3aef61d0b66d726e85
PREREG_S7_D_v3_8.md (1차)	58b4a7f35249769716dca6316ab84cdc22d6259c88bd94a385a60f8a3c9bcd8b
감사 파일	shared/audits/AUDIT-P011~P014_*.md

A-2. 4차 체크포인트·스크립트 (서버)

파일	SHA-256
results_s7/g2v2/decoder_M7A_v36.pt	46977c2db533888dc13a8defe21ac287b26bd7ff1e08bb83eb22a4ca4bb99670
results_s7/g2v2/decoder_M7E_v36.pt	d0c33599c9586d3ed131877a2439ee09d5d48804a0408965daaa0238705afd5a
results_s7/g2v4m7rep/deq_Ah.pt	b43de6b0eeb0a16a5f04762ac9c6a95979e504bc48f8b52249213490d6485cf7
results_s7/g2v4m7rep/deq_Eh.pt	7e9dc5feb1e563996e90cc825c3567e54caadb86f5a9a25ce03435df37be9788
scripts/g2v4_m4_pilot_train.py (학습)	f492da0f1c35a3088397d2fec1748e9b56ed82bc3b371fe33cc0846706092ab0
scripts/g2v4_proj_v2.py (V2 연결부)	7cabcef2e13bb524a6815add5198853f21e8437fd04d018a6cef2227161df47a
scripts/s7_eval_gate_p6_v36f.py (생성)	fd6c2d03e3ed18d1597950edc79a01af8331d192c9f84b821a5b5bcf3f71cfe1
scripts/g2v3_m3_eval_latents_v2.py (한 걸음 잠재)	73db9dafd33e49e963d48aad4797c6b0eb7856e5e8e847fbb3b8dc0e5109921b

scripts/cc_g2v4_confirm.sh (확증 실행본)	d74fd9a96dc246028c09adc31adc736c672d5dc7ec50b6c0533965af261ca9bb
cc_g2v4_confirm_resume1.sh (재개 1 최종)	9c905cef5e5410fa9c1feb951f62afb363b4a5633140b603cfb709c636ec4f87
g2v4_fresh_prep_r1.py · g2v4_proximity_r1.py	e8876570b4f20360f8e40a286ad73fff28531d983e35cae24c30df0e34ed133f · 0d602101af358fdb0cfe873032e972b686a297b0b3a2c82df7e0dea0d904f0e8
채점기 · 채점 스크립트	90cc93e4b76704b209291ac43999a3f829ac79f7234c60362f95bccadd12fa13 · 547e1d91aa998908a0c436198f9890be961f18d643efec2c43dd700d415587cd

A-3. 문항 목록

파일	SHA-256
configs/g2v4b_fresh.json (4차 1,758, 사용 완료)	6e68e34c510593fb017d7dab5296c60ac506ce28d1ddeb3701231a69f696ce80
샤드 0 · 1 · 2	f8f305a1… · c5a3ce59… · 63935a09…
configs/g2v2_fresh1000.json (3차 1,000, 사용 완료)	35683874284b371c6641e1280b92e6a69292a2dc5d89585158154a45b41cb3db
configs/s7_train_993.json (학습)	3088a153f1d7ffabf77423a9354cd97795b9dae2daa7f429255bacfd4293784c
results_s7/p6_item_order.json (개발 600)	6c76ddb7cc4a1ee901291eee76ed99763ec5ebfec202cb30ba17f9bcee487e7c

A-4. 4차 결과물

파일	SHA-256
g2v4fresh_merged/gate_table.json	ea120d95bebf842e08b74a65b43178466ab7149aa5b10a687ab0d5bff37930a4
p6_gen_A.jsonl	e2edee7395421bdec447f7a6c75f27ef88f5dc230bbd2736ac87d2f22638ed66
p6_gen_B1.jsonl	3fdab13810e24da6b5353ef235588c9aa9c5b3ff177448cbfb7ee0a5009873a8
p6_gen_C.jsonl	1b130c2ece04c37021a9191e567773e82875ef49f8f1dbeab833b26520147372
p6_gen_E1.jsonl	d16f4bb557522baf988a9a1cd77ec3db3b1a6dcda2d661986995efc7ce8db5b0
raw_s7/g2v4_fresh_score.log	2b11f68b390243d26aff27f7c409b08c03bde8f46f59be5f8e42b2c9bc44a8d8
개발 600 채점 dev_score.json	e890c3c2d6fcf5981a195b785925ae7e3963f700809b9bfa0b66411b83e4f695

3차 gate_table.json	71f6bc260318b16b2a65799d75650c5080c41e19ba9f3842ee37f6f6c4763b73

부록 B. 로그와 원시 출력 위치

내용	위치 (로컬 D:\AI\cts\ 기준)
4차 판정 문서	shared/reports/RESULT-G2v4-confirm.md
4차 채점표·채점 로그·마스터 로그(원본·재개)	shared/reports/g2v4fresh/ (gate_table.json·md, g2v4_fresh_score.log, cc_g2v4_confirm_master.log 3507a21e…, cts_g2v4_resume1_master.log e04f01ba…)
근본 원인 진단 전문과 원자료	shared/reports/DIAG-G2v4-rootcause-20261011.md, g2v4diag/, g2v4v2/, g2v4deqlr/, g2v4m7rep/, g2v4posctl/
개발 600 정확도	shared/reports/g2v4dev/ (dev_score.json·md, cc_g2v4_dev_m7.log)
새 문항 선택·id 검사·잠금 증거	scratch/cc_g2v4_select_outputs.txt, cc_g2v4_evidence.txt, cc_g2v4_idscan_posctl.txt, cc_g2v4_lock_evidence.txt
근접도 보고	scratch/cc_g2v4_proximity.txt
3차 결과	shared/reports/RESULT-G2v3-confirm.md, g2v3fresh/
1·2차 결과	RESULT-P6R-G2-main.md, RESULT-G2v2-dev.md, DIAG-P6R-local-20261008.md
진행 기록·가설·접속 기록	shared/STATE.md, shared/GRAPH.md(H-DEC-7 채택), shared/ssh_log.csv
핵심 결과 백업 요약	shared/reports/BACKUP_SUMMARY_20261011.md
서버 쪽 원본	/home/shoon/cts_e1_s5/results_s7/p6r/g2v4fresh_merged/, raw_s7/g2v4_*, 재현용 텐서 /tmp/cts_g2v4_shoon/(휘발성)

CTS 프로젝트 진행 보고서 v4 · 2026-10-12 · 작성 회사 PC Claude Code(CC). 숫자는 모두 원자료(JSON·로그·SHA)에서 옮겼고 CC가 핵심 p값을 따로 다시 계산했다. 이전 판 v3(10/8)·v2는 같은 폴더에 백업으로 보존.