CTS 프로젝트 진행 보고서 — DEQ 고정점의 수렴·변별(G1)과 디코더 기여(G2)

기준 시각 **2026-10-28 10:xx KST (v5 + X8-B~X8-E·정보 탐침·ENC 1단계·2-1 반영)** 작성 **회사 PC Claude Code(CC, 설계·실행·감사 요청)**
독립 감사 **B(AI 서브에이전트) · 코덱스(독립 재계산·코드 검토) · AG(서버 없는 CPU 숫자 검증)** 서버
/home/shoon/cts_e1_s5 (RTX A6000 ×8, 4차는 GPU 5·6·7) 이전 판 **v5 (10/25) · v4.9 (10/14) · v3 (10/8) 백업 보존**

G1 · DEQ 수렴·변별

사전등록 기준 충족 · 확정

신규 held-out 520 중 517 수렴, 최근접 일치 519/520, 평균 cos 0.569.

G2 1~3차 시도 (10/7~10/11)

기준 미충족 · 확정

1차 게이트 4 −4.83%p, 2차 개발 단계 중단, 3차 게이트 4 +1.20%p(p 0.097).

G2 4차 · M7 수정형 시스템 (10/12)

자체 사전등록 기준 충족

새 1,758문항 1회. 게이트 4 A−E‴ +2.33%p, 95% CI [+0.91, +3.70], p 0.000717. 원래 GOAL의 G2 통과로 보지 않는다.

DEQ 반복 계산의 정보 기여 (최종 확인 2-1)

더하지 않음 · 원인 확정

정답 단서가 담긴 새 메모에서 DEQ를 반복해도 단서가 늘지 않음(정답 형태 −4.5%p). 이득은 전부 인코딩 몫(19·20절).

탐색 X 계열 · 잠재→LM 통로 (10/19~23)

통로 확보 · 부분 개방

cross-attention 브리지 + 자기 생성문 표적: 오라클 matched−shuffled +3.56%p, 3시드 CI [+1.61, +5.50]. 그러나 순정 대비 이득 0.

1. 요약

CTS는 언어모델이 문제를 읽고 만든 잠재 상태를 같은 규칙으로 1,000번 반복해 고정점 z*를 얻는 구조(DEQ)를 검증한다. 두 가지를 묻는다. G1은 "z*가 안정적으로 수렴하고 문항마다 다른가"이고, G2는 "z*를 디코더에 넣으면 수학 문제를 더 잘 푸는가, 그 이득이 반복 전 잠재 z_src보다 큰가"이다. 모든 판정 기준은 결과를 보기 전에 사전등록하고 SHA-256으로 잠갔으며, 독립 감사자 B가 감사했다.

G1은 10/7에 확정됐다. G2는 1~3차 시도에서 모두 게이트 4(DEQ 귀속)를 넘지 못했다. 10/11 진단에서 근본 원인을 찾았다. 잠재를 언어모델에 넣는 투영기가 실제 단어 임베딩보다 25~40배 큰, 모든 문항에 같은 상수 벡터를 넣어 문항 정보가 2~4%로 묻혔다. 그래서 1~3차의 모든 디코더는 잠재를 "고정 soft prompt"로만 썼다(자기 잠재 = 남의 잠재 = 평균 잠재의 NLL).

이 결함을 고친 연결부(PrefixProjectorV2)와 더 강하게 학습한 DEQ 사상으로 4차 방법 M7을 만들었다. 새 사전등록 PREREG_S7_G2v4를 AI 감사 에이전트 B의 감사 3회 뒤 잠그고, 이 프로젝트에서 한 번도 쓰지 않은 1,758문항으로 한 번 평가했다. **결과는 M7 수정형 전체 시스템이 자체 사전등록 기준을 충족한 것이다.** 원래 GOAL의 G2(정본 z*)가 통과된 것으로 보지 않으며, 기존 G2 1~3차는 미통과로 둔다. 게이트 2·3은 A−C +8.08%p(142/0), 게이트 4는 A−E‴ +2.33%p(100/59, 정확 McNemar 단측 p 0.000717, 95% CI [+0.91, +3.70])이다. 4회 시도를 감안한 참고값 p×4 = 0.0029로도 기준 아래다.

해석의 한계도 함께 적는다. (1) A·E는 DEQ 시작점만 다른 조건이 아니다. A에만 보조 손실(λ_ift 0.1)이 들어갔고 decoder와 학습 경로도 달라, A−E 차이를 DEQ 반복 자체의 효과로 보기 어렵다. (2) 보조 게이트 A−B1(다른 문항의 잠재)은 +0.46%p, p 0.26으로 유의하지 않다. 이득이 문항별 잠재 내용에서 왔다는 증거는 정확도 수준에서 아직 없다. (3) A 입력은 GOAL의 "정본 z*"가 아니라 M2′ 고정점에 학습된 한 걸음을 더한 것이다. 따라서 **DEQ 고유 효과와 문항별 latent 기여는 미확인**으로 기록한다.

감사 주체 공개. 이 보고서의 "B"는 사람이 아니다. CC(Claude Code)가 같은 Claude 시스템 안에서 따로 띄운 AI 감사 서브에이전트로, 로컬 파일만 읽고 서버에는 접속하지 않았다. 실행 에이전트 AG(Antigravity)도 AI다. 외부 사람의 독립 검증은 아직 없다.

---

2. 진행률과 일정

목표	진행률	상태
G1 DEQ 수렴·변별		100% · 확정(10/7)
G2 1차 (P6R)		100% · 기준 미충족(확정)
G2 2차 (M2′)		100% · 개발 선택 규칙에서 중단(확증 없음)
G2 3차 (M3)		100% · 기준 미충족(확정)
G2 4차 (M7)		100% · **사전등록 기준 충족**(10/12 05:48)
GOAL G2 인정		미통과로 정리(CTS-432·435) · 원인 확정(16절)
진단 R1·S0·S1·S2 (10/12~14)		100% · 형식 혼입 규명, 연결부 병목
탐색 X1·X3·X5·X6 통로 수리 (10/19~20)		100% · 오라클 전달 재현(+3.56%p), 순정 대비 0
탐색 X7·X8-0·X8-A 잠재 내용 (10/20~23)		100% · DEQ 잠재 내용 없음(종결)
v5 이후 원인 좁히기 X8-B~X8-E·탐침 (10/24~26)		100% · 메모에 답의 단서 없음 확인
ENC 1단계 (10/27)		100% · 새 인코딩은 단서를 담음(8/8 통과)
2-1 DEQ 반복의 기여 (10/28)		100% · 더하지 않음 → 현 구조 G2 재도전 근거 없음
10/28 미팅 결정		(가) 진단 연구 마무리 / (나) 새 인코딩+정보를 더하는 DEQ 목표의 새 연구

경과

10/07 11:2x	**G1 확정**(RESULT-G1-final.md).
10/07 23:5x	G2 1차(P6R, 정지 토큰 결함 수정 재평가) 판정: 게이트 4 −4.83%p로 **기준 미충족**.
10/08	원인 진단 1: 정본 주입(문제 토큰 평균 1개)이 고정점에서 문제 정보를 지움 → M2′(주입 = z_src). PREREG_S7_G2v2 잠금(B 감사 4회).
10/09	G2 2차 개발 600: A′ 7.50% 대 E′ 7.83% → 선택 규칙 미충족, 새 문항을 열지 않고 중단.
10/10 23:55	G2 3차(M3: DEQ 사상과 디코더 공동 학습) 사전등록 PREREG_S7_G2v3_1 잠금(AG가 감사 없이 잠근 원본을 CC가 멈추고 사후 감사 AUDIT-P013 → 개정).
10/11 08:23	G2 3차 확증(새 1,000문항): 게이트 4 +1.20%p, p 0.0973 → **기준 미충족**.
10/11 08:5x ~ 13:2x	원인 진단 2(개발 600만 사용): 잠재 내용 미사용 확인 → 짝 맞춤 정상 → 투영기 출력 크기 결함 발견 → 양성 대조로 "DEQ 잠재에 쓸 내용 부족" 확인 → Φ_θ 강학습에서 첫 양의 신호.
10/11 13:23 ~ 16:27	M7 복제(2시드) 후 개발 600 정확도 1회: A 7.83% 대 E‴ 4.83%, +3.00%p, p 0.0137(판정 아님).
10/11 16:3x ~ 17:15	새 문항 1,758 선택·id 전수 검사(적중 0), PREREG_S7_G2v4 작성 → B 감사 FIX 5건 → 재FIX 2건 → **PASS·잠금**.
10/11 17:18	4차 확증 착수(GPU 5·6·7). z*′ 1,758문항 계산 21:04 완료.

10/11 21:04	서버 /home 디스크 100%로 병합 단계 저장 실패(채점 전). 사전등록 §5 재개 규칙·B 사전 확인으로 21:25 재개(큰 텐서는 /tmp, 결함 파일은 삭제 없이 이동).
10/12 05:48	생성 7,032건 완료·채점 → **G2v4 사전등록 기준 충족**.

3. 판정 기준 (결과 보기 전에 잠금)

목표	기준	사전등록 · SHA-256
G1	신규 520 수렴 ≥90%, 문항 간 평균 cos ≤0.75, 최근접 일치 ≥99%, 앵커 재현	`PREREG_S7_DEQ_v1.3/1.4` · 254beb6f… · 04112522…
G2 (공통)	게이트 2(A−C ≥ −2%p) ∧ 게이트 3(A−C: 정확 McNemar 단측 p<0.025 ∧ 부트스트랩 95% 하한>0) ∧ 게이트 4(A−E: 같은 기준), strict 채점. 게이트 1(A−B1)은 보조	`shared/GOAL.md`
G2 1차	위 기준, held-out 600	`PREREG_S7_D_v3_8` · 58b4a7f3…
G2 2차	개발 선택 규칙(A′−E′ > 0 ∧ A′−C > 0) → 새 1,000	`PREREG_S7_G2v2` · 4ea1d966…
G2 3차	개발 선택 규칙 → 새 1,000, p×3 참고	`PREREG_S7_G2v3_1` · 3d1a6ee0…
G2 4차	새 1,758 한 번, 판정 키 `gates.Gate_{2,3,4}.strict`, p×4 참고	`PREREG_S7_G2v4` · 5923fef7…

채점기 `scripts/s5_eval_grader_v2.py`(90cc93e4…), 채점 스크립트 `s7_eval_score_p6_v36.py`(547e1d91…), 부트스트랩 10,000회·시드 2026은 모든 시도에서 같다.

4. G1 결과 — DEQ 수렴·변별 (확정)

항목	값	기준	판정
①-b 확증 · 신규 520 수렴	517/520 (99.4%)	≥90%	충족
①-b 보조 · 600	596/600	≥90%	충족
①-a 보조 · train 1,000	991/1000	≥95%	충족
문항 간 평균 cos	0.569	≤0.75	충족
최근접 일치율	519/520	≥515	충족
앵커 재현	20/20 cos≥0.99999997	cos≥0.9999	충족

G1은 사전등록한 최저점 규칙으로 충족했다(1,000번째 최종점 기준 456/520). G1 충족은 "고정점이 안정되고 문항마다 다르다"까지만 뜻한다.

5. G2 시도별 결과

시도	방법	문항	A	E	C	게이트 4 (A−E)	판정
1차 P6R	정본 z* + v3.6 투영기	600	1.67%	6.50%	0.33%	-4.83%p, 7/36	미충족
2차 M2′	주입 = z_src	개발 600	7.50%	7.83%	0.33%	-0.33%p	개발 중단
3차 M3	DEQ 사상 + 디코더 공동 학습	새 1,000	6.50%	5.30%	0.10%	+1.20%p, 42/30, p 0.0973	미충족

4차 M7	**V2 연결부 + Φ_θ 강학습 + 글 가리기**	새 1,758	8.08%	5.75%	0.00%	+2.33%p, 100/59, p 0.000717	충족

정확도는 strict(\boxed{} 정답) 기준이다. 1·3·4차의 게이트 2·3은 모두 충족했다(1차 A–C +1.33%p p 0.0193, 3차 +6.40%p, 4차 +8.08%p).

---

6. 근본 원인 진단 (10/11, 개발 600만 사용)

진단은 이미 열람한 개발 600과 학습 문항만 썼다. 새 문항은 열지 않았다. 지표는 정답 해설의 teacher-forced 평균 NLL이다. 전문: `shared/reports/DIAG-G2v4-rootcause-20261011.md`.

6-1. 디코더는 잠재의 문항 내용을 쓰지 않았다

디코더	자기 잠재	다음 문항 잠재	평균 잠재(상수)
3차 A	0.8782	0.8777	0.8767
3차 E‴	0.8933	0.8941	0.8933

글을 가리고 학습(M4), 처음부터 글 없이 학습(용량 파일럿), 언어모델에 LoRA를 붙여도 같았다. 학습 문항에서도 같았다. 데이터 짝짓기는 정상이었다(정본 로더 재계산 cos 1.0, 검색 20/20).

6-2. 원인: 투영기 출력의 크기와 상수 지배

단계	문항 고유 에너지 비율	칸당 norm
입력 z_src	0.576	288.7
3차 E 디코더 · `w_proj` 뒤	0.101	141
3차 E 디코더 · 어댑터 뒤(LM 입력)	0.027	1,258
참고: 실제 단어 임베딩	–	50.5

64칸 자리는 LM이 읽을 수 있다. 글 없이 그 자리에 자기 문제의 단어 임베딩을 넣으면 NLL 2.711 → 2.376, 다른 문제는 2.633.

6-3. 잠재 내용과 해결 실마리

- 크기를 맞춘 V2 투영기로도 DEQ·z_src 잠재의 문항 내용 사용은 없었다(z ≤ 1.2). 잠재를 단어로 풀면 무의미한 문자열이다. 문제 글 은닉 상태를 잠재로 쓴 양성 대조는 같은 경로로 정보가 약하게 전달됐다(z 2.7). 즉 **DEQ 잠재 자체에 LM이 쓸 내용이 거의 없었다.**
- DEQ 사상 Φ_θ(문제 글을 attention으로 읽음)를 10배 학습률로 학습하자, DEQ 고정점에서 출발한 A 잠재만 문항 특이성이 생겼다(z 2.7, 복제 z 4.4). z_src 출발 E는 z 0.6. A–E NLL −0.0236(z −7.2).

---

7. 4차 방법 M7

구성	내용
고정점	M2′(주입 = z_src, α = g_0 = 0.25, 1,000번 반복)로 학습 전 사상 Φ_0에서 계산한 $z^{*\prime}_0$
학습된 한 걸음	$T_\theta(z) = (1-\alpha)z + \alpha[\Phi_\theta(z) + g_0 \cdot z_{src}]$, Φ_θ = LoRA r8 q·v·o + routing_proj + γ
연결부	PrefixProjectorV2: 학습 시작 잠재의 칸별 평균을 빼고 RMS 정규화 → `w_proj`(항등 초기화) → MLP 어댑터 → RMS 정규화 × 실제 단어 RMS(0.9981)
학습	3,000단계, 배치 4, 학습 993문항, lr 투영기 1e-4·어댑터 3e-4·DEQ 3e-4, 글 가리기 0.5, 시드 2047. λ_ift A 0.1 · E 0. A·E 모두 993/993, 가리기 6,061회로 같음
조건	A = decoder_M7A + $T_{\theta,A}(z^{*\prime}_0)$ · E‴ = decoder_M7E + $T_{\theta,E}(z_{src})$ · C = 순정 Gemma 글만 · B1 = A 디코더 + 한 칸 민 A 잠재

8. 4차 확증 결과 (새 1,758문항, 1회)

조건	strict	lenient
A · M2′ 고정점 → 학습된 한 걸음 + V2	8.08%	12.91%
B1 · A 디코더 + 다른 문항 A 잠재 (보조)	7.62%	12.86%
E‴ · z_src → 학습된 한 걸음 + V2	5.75%	11.60%
C · 순정 Gemma, 글만	0.00%	8.02%

게이트	비교	Δ	95% CI	b/c	p	p×4	결과
2 바닥선	A − C ≥ −2%p	+8.08%p	[+6.83, +9.33]	142/0	–	–	충족
3 기여	A − C	+8.08%p	[+6.83, +9.33]	142/0	<1e-6	<4e-6	충족
4 DEQ 귀속	**A − E‴**	**+2.33%p**	**[+0.91, +3.70]**	**100/59**	**0.000717**	**0.0029**	충족
1 보조	A − B1	+0.46%p	[-0.80, +1.65]	64/56	0.2615	–	유의하지 않음

원자료 `shared/reports/g2v4fresh/gate_table.json`(ea120d95…). CC가 b = 100, c = 59의 정확 이항 단측 p를 따로 계산해 0.000717로 일치를 확인했다. 판정 문서 `shared/reports/RESULT-G2v4-confirm.md`. 보고 항목(판정 미사용): 한 걸음 상대 이동 중앙값 A 0.1266 · E 0.1058.

9. 실행 경과와 사고 처리

- 착수 10/11 17:18:14. 사전 점검에서 SHA 21개 일치, 출력 없음, GPU 5·6·7 비어 있음.
- z*′ 1,758문항: 21:00/21:00/21:04 완료, 1,758/1,758이 r_1000 < 1e-2.
- **21:04 서버 /home 디스크 100%(여유 0)로 병합 파일 저장 실패.** 채점 전이라 결과는 없었다. 사전등록 §5의 재개 규칙에 따라 재개 스크립트를 만들고 B의 사전 확인("실행 가능")을 받았다.
  - 큰 텐서(약 6GB)는 루트 디스크 `/tmp/cts_g2v4_shoon`(권한 700)에 썼다.
  - 잘린 결함 파일(2.72GB)은 지우지 않고 그 폴더로 옮겨 /home에 생성 결과용 공간을 확보했다.
  - 실패한 단계부터 같은 명령으로 실행했고 이어 쓰기는 없었다. 생성·채점 명령, 문항, 체크포인트는 바뀌지 않았다.
- 재개 21:25 → 잠재 LOAD-GUARD 436·0 ×2, PROJ-V2 확인 9개 로그 → 병합 4조건 각 1,758행·오류 0 → 채점 05:48:20.

10. 품질 관리 — 감사 이력

> **감사자 B는 AI다.** AUDIT-P011~P014의 감사자 B는 CC가 같은 Claude 시스템 안에서 띄운 별도 AI 서브에이전트다(로컬 파일만 읽음, 서버 접속 0). 같은 실행 체계 안의 감사이므로 외부 사람의 독립 검증과 같지 않다.

감사	대상	결과
AUDIT-P011	PREREG_S7_D_v3_8 (1차)	FIX 12 → 3 → PASS
AUDIT-P012	PREREG_S7_G2v2 (2차)	FIX 13 → 5 → 4 → PASS. 새 문항 목록과 겹치는 서버 파일 35개 발견 → 보수 제외

AUDIT-P013	PREREG_S7_G2v3 (3차, 사후 감사)	AG가 감사 없이 잠금 → CC가 확증을 멈춤. FIX 8 → 4 → PASS. 개발 A 80문항이 옛 z*를 받은 키 결함을 찾아 다시 함
AUDIT-P014	PREREG_S7_G2v4 (4차)	FIX 5(원시 근거·Ez 공개·공정성·GOAL·스크립트 가드) → 재FIX 2 → PASS. 재개 1 사전 확인 "실행 가능"

새 문항 1,758의 사용 흔적은 서버의 `.jsonl` 72개 id와 `.pt` 374개 키를 모두 대조해 0건이었다. 같은 검사기로 3차 사용 목록을 검사하면 23개 파일에서 적중해, 검사기가 실제로 흔적을 잡는다는 것도 확인했다.

---

11. 한계와 해석

1. **λ_ift 혼입.** 게이트 4는 "DEQ 시작점 때문"과 "A만 받은 IFT 보조 손실 때문"을 가를 수 없다. 개발 진단에서 같은 A 디코더에 입력만 T_θ,A(z_src)로 바꾸면 NLL 차이가 0.0011뿐이었다. A−E 차이의 대부분은 학습 경로에서 온다.
2. **문항 내용 기여 미확인.** 보조 게이트 A−B1 +0.46%p(p 0.26). 정확도 수준에서는 다른 문항의 A 잠재로도 비슷하게 맞힌다.
3. **GOAL 표현과의 차이.** A 입력은 GOAL의 "정본 z*"가 아니다(z*'₀에서 중앙값 12.7% 이동). 평가도 GOAL의 "held-out 600"이 아니라 새 1,758문항이다.
4. **다중 시도.** 4차 시도다. p×4 = 0.0029.
5. **설계 선택.** M7 설정은 개발 600의 NLL 진단을 여러 번 보고 골랐다(선택 편향 가능). 정확도는 개발에서 한 번만 봤고, 판정은 새 문항으로만 했다.
6. **단일 시드·로더.** A·E 디코더는 시드 하나다. 고정점은 정본 로더로, 학습된 한 걸음은 학습 스크립트의 로더로 계산했다(같은 문항 z_src cos 0.70~0.91, A·E 동일 조건).
7. **절대 정확도.** 가장 높은 A도 strict 8.08%다. 이 평가는 상대 비교(게이트)를 위한 것이며 실용 수준의 성능 주장이 아니다.

---

12. 1단계 견고성 실험 R1·R1x (10/12~13, 개발 600, 판정 아님)

CTO 의견(CTS-432)에 따라 {A, E} × {보조 손실 λ_ift 0, 0.1} × 시드 3(2047·2049·2050)을 같은 레시피로 학습해 원인을 분리했다. 새 문항은 쓰지 않았다. 해석 규칙은 결과 전에 고정했다 (`shared/proposals/R1_ROBUSTNESS_PLAN_20261012.md`). 전문: `shared/reports/RESULT-R1-robustness-20261012.md`.

12-1. 같은 학습 조건의 A − E (strict)

λ_ift	시드 2047	시드 2049	시드 2050	평균
0	+4.83%p (p 0.0002)	-6.00%p	-0.50%p	-0.56%p
0.1	-1.83%p	-3.17%p	-6.33%p	-3.78%p

시드 평균 strict: A λ0 5.72%·λ0.1 4.11%, E λ0 6.28%·λ0.1 7.89%. A 일부 시드는 답 형식(`\boxed`)을 거의 내지 못해 정확도가 0.17%·1.83%로 무너졌다.

12-2. 같은 A 디코더에서 matched z* − shuffled z* (strict)

디코더	Δ	95% CI	b/c	p
Ah (λ0.1, 2047, 4차 모델)	+2.33%p	[+0.33, +4.33]	25/11	0.014
R1A0s47 (λ0, 2047)	+3.50%p	[+1.50, +5.50]	29/8	0.0004
R1A0s49 (λ0, 2049)	+0.17%p	[-1.33, +1.67]	10/9	0.50
R1A0s50 (λ0, 2050)	+0.83%p	[-1.33, +3.00]	25/20	0.28

R1A1s49 (λ0.1, 2049)	+1.67%p	[-0.33, +3.67]	23/13	0.066
R1A1s50 (λ0.1, 2050)	+0.17%p	[0.00, +0.50]	1/0	0.50

NLL로 보면 잠재 주입 효과(no-injection 1.918 → 디코더 0.83~0.93)는 대부분 문항 무관이며, matched−shuffled 차이는 0.002~0.005로 A·E 모두에 비슷하게 있다.

12-3. CTO 기준 판단

기준	결과	판단
(1) 같은 학습 조건에서 matched z* > matched z_src, 시드 전반 일관	6쌍 중 A 유의 우위 1, E 유의 우위 3, 시드 평균 E 우위	불충족
(2) 같은 디코더에서 matched z* > shuffled z*, 유의	6개 중 유의 2(모두 시드 2047)	시드 전반 불충족

> **읽은 것.** 4차 확증의 게이트 4 충족은 사전등록에 고정된 모델 쌍(Ah·Eh, 시드 2047)에 대해 절차상 유효하다. 그러나 R1은 그 이득이 M7 방법의 일반적 성질이 아니라 특정 시드·학습 경로의 결과일 가능성이 크다는 것을 보여 준다. 두 기준 모두 시드 전반에서 확인되지 않았으므로, CTO 지침대로 5차 확증과 새 test 데이터 개봉은 하지 않는다.

12-4. 시드 2047 원인 분석과 S0 (10/13, 새 학습·새 생성 0)

CTO 답신(CTS-433)에 따라 기존 체크포인트·로그·생성만으로 분석했다. 전문: `shared/reports/DIAG-seed2047-forensic-20261013.md`.

- 모델 12개에서 strict 정확도와 \boxed 비율의 상관 0.94, 투영기 출력의 문항 고유 비율과의 상관 −0.85. 잘 푸는 디코더일수록 문항 정보를 지워 공통 prefix만 넘겼다.
- 시드 2047의 A 디코더 두 개는 문항 변동을 거의 지웠고(0.46%·0.17%), 4차에서 짝지은 Eh는 E 중 유일하게 변동을 크게 통과시켜(23.8%) 형식 준수가 가장 낮았다.

4차 새 1,758문항 A − E‴ (같은 원자료)	Δ	b/c	p
strict 전체 (사전등록 판정 지표)	+2.33%p	100/59	0.0007
lenient 전체	+1.31%p	109/86	0.058
둘 다 \boxed를 낸 332문항 · strict	+3.01%p	37/27	0.130
\boxed 비율	A 43.1% · E‴ 31.4%		
형식을 지킨 답 안의 정답률	A 18.8% · E‴ 18.3% · B1 18.1%		

> **읽은 것.** 4차 게이트 4의 차이는 대부분 답 형식(\boxed) 준수 차이에서 왔다. 형식을 지킨 답 안에서는 A·E‴·B1의 정답률이 거의 같고, 둘 다 형식을 지킨 문항에 한정하면 A − E와 matched − shuffled가 개발·4차 어디에서도 유의하지 않다. DEQ 잠재의 내용 기여와 문항별 기여는 확인되지 않았다. 4차 판정 자체(사전등록 strict 지표)는 바꾸지 않는다.

12-5. S1 형식 지시 고정 실험 (10/13~14, 개발 600, 판정 아님)

모든 조건의 프롬프트에 "Put your final answer within \boxed{}."를 고정하고 {A, E} × λ_ift 0 × 시드 3으로 다시 학습했다(사용자 지시로 착수). 전문: `shared/reports/RESULT-S1-format-fixed-20261014.md`.

시드	A strict	E strict	A − E (b/c)	A matched − shuffled (p)
2047	4.83%	8.17%	-3.33%p (18/38)	+0.50%p (0.375)
2049	7.00%	8.67%	-1.67%p (27/37)	+1.17%p (0.205)
2050	3.83%	6.33%	-2.50%p (15/30)	+1.00%p (0.203)

> **읽은 것.** 기준 (1)·(2) 모두 불충족. 형식을 글에 고정해도 A의 `\boxed` 비율(26~44%)이 E(42~54%)보다 낮고, 형식을 지킨 답 안의 정답률은 A·E가 같다(약 15~16%). 형식 혼입을 줄인 조건에서도 DEQ 시작점이 z_src보다 낫다는 증거는 없고 3시드 모두 E가 낫다.

S1 같은 형식 조건	strict	lenient	\boxed	형식 지킨 답 안 정답률
C · 순정 Gemma (잠재·디코더 없음)	**12.83%**	**15.67%**	**35.5%**	**36.2%**
A 디코더 3개	3.83~7.00%	6.17~10.00%	26.3~43.5%	14.6~16.1%
E 디코더 3개	6.33~8.67%	10.17~11.17%	42.3~54.0%	15.0~16.0%

> **추가로 읽은 것.** 형식 지시만 주면 순정 모델(C)이 잠재+디코더 조건 모두보다 잘 푼다. 1~4차의 게이트 2·3(A − C +6~+8%p)은 C가 형식 지시 없이 `\boxed`를 거의 쓰지 않은 데서 왔다(4차 C `\boxed` 4/1,758). 같은 형식 조건에서는 잠재 prefix가 풀이를 오히려 방해한다.

12-6. S1을 CTO 지표로 다시 분석 (10/14, 새 학습·생성 0)

CTO 지침(CTS-434: lenient 주 지표, `\boxed` 비율 선확인, 시드 반복을 반영한 문항 단위 cluster bootstrap, 세 시드 종합 matched−shuffled CI 하한 > 0)은 S1 종료 뒤 전달되어, S1은 원래 계획 기준으로 실행됐다. 아래는 기존 문항별 채점을 CTO 지표로 다시 계산한 것이다(bootstrap 10,000회).

점검	결과	판단
⓪ 모든 조건 `\boxed` 비율이 충분히 높고 비슷한가	C 35.5%, A 26~44%, E 42~54%, shuffled 26~53%	불충족
① A − E · lenient (주)	-2.83%p, 95% CI [-4.50, -1.22]	E 유의 우위
① A − E · strict (보조)	-2.50%p, CI [-4.06, -1.00]	같은 방향
② A matched − shuffled · lenient (핵심)	**+1.17%p, CI [-0.17, +2.50]**	불충족 (하한 < 0)
② A matched − shuffled · strict (보조)	+0.89%p, CI [-0.33, +2.11]	불충족
참고 · E matched − shuffled · lenient	-0.89%p, CI [-2.33, +0.56]	차이 없음

전문: `shared/reports/RESULT-S1-format-fixed-20261014.md` §7, 원자료 `shared/reports/s1/s1_items.json`. CTO 지침대로 S2는 바로 시작하지 않고 결과와 진단부터 공유한다.

12-7. S2 오라클 잠재로 연결부 용량 점검 (10/14, 탐색 · 판정 아님)

CTO 사전 통보 뒤 진행한 탐색 실험. 정답 해설 글의 은닉 상태(마지막 64토큰)를 "오라클 잠재"로 만들어, DEQ 한 걸음 없이 같은 연결부(V2 투영기 → 64칸 prefix → 고정 Gemma)로 학습·평가했다. 판단 규칙은 결과 전에 고정했다(`shared/proposals/S2_ORACLE_PLAN_20261014.md`). 전문: `shared/reports/RESULT-S2-oracle-20261014.md`.

조건	\boxed	lenient (주)	strict
C-fmt · 순정 Gemma + 형식 지시 (잠재 없음)	**35.5%**	**15.67%**	**12.83%**
오라클 matched · 시드 2047 / 2049 / 2050	39.3 / 19.3 / 1.2%	11.50 / 5.50 / 0.33%	9.17 / 3.67 / 0.00%
오라클 shuffled · 시드 2047 / 2049 / 2050	39.3 / 21.2 / 2.2%	9.67 / 5.33 / 0.50%	7.50 / 3.33 / 0.17%

사전 규칙	결과 (lenient, cluster bootstrap)	판단
A · matched − shuffled CI 하한 > 0	+0.61%p, CI [-0.78, +1.94]	불충족
B · matched − C-fmt ≥ +5%p	-9.89%p, CI [-12.67, -7.28]	불충족 (반대 방향)
NLL · matched vs shuffled 오라클	차 0.0005~0.021 (글 없음 조건도 동일)	내용 전달 없음

> **판정(사전 규칙): 연결부가 병목이다.** 정답을 통째로 담은 잠재로도 자기/남 구별이 없고, 잠재 없는 순정 모델보다 약 10%p 낮다. 투영기 → 64칸 prefix → 고정 LM 경로는 어떤 잠재의 내용도 정답률로 바꾸지 못하며, prefix 주입 자체가 풀이를 방해한다. DEQ 잠재에 내용이 있는지는 이 연결부로는 알 수 없다. 사전 규칙의 다음 단계는 새 연결부 시제품이며, 설계안을 먼저 공유한다.

---

13. 다음 단계 설계안 (검토용 · 승인 전 실행 없음)

CTO 의견(CTS-433)에 따라 A 안정화·새 학습 목표·IFT를 동시에 진행하지 않고, 아래 설계안을 먼저 공유한다. S0(새 학습 없음)은 12-4절에서 완료했다. S0 결과 형식(`\boxed`) 준수가 가장 큰 혼입 요인이므로 S1을 먼저 제안한다.

안	내용	새 학습	무엇을 확인하나	상태
S0	기존 생성 재채점: lenient, 형식을 지킨 답 안의 정답률, 둘 다 형식을 지킨 문항 한정 비교	없음	형식을 빼면 내용 효과가 남는가	완료
S1	형식 지시를 모든 조건의 프롬프트에 고정해, 형식은 글이 담당하고 잠재는 내용만 담당	있음	형식 혼입을 없앤 뒤 A > E, matched > shuffled가 생기는가	완료 · 두 기준 불충족 (12-5)
S2	통로 용량 점검: 정답 정보가 든 오라클 잠재로 같은 경로를 학습	있음	이 연결부가 문항 내용을 정답률로 바꿀 수 있는가	S1 뒤 검토
S3	두 채널 분리: 공통 soft prompt(형식) + 0에서 시작하는 게이트 잔차(문항 내용)	있음	내용이 형식을 깨지 않고 더해지는가	S1·S2 뒤 검토

13-1. S1 상세 설계

항목	내용
바꾸는 것 한 가지	학습과 평가의 프롬프트에, 모든 조건(A·E·B1·C)에서 같은 형식 지시 문장을 문제 글 뒤에 고정한다. 예: "Put your final answer within \boxed{}." 글 가리기로 문제 글을 빼는 학습 단계에서도 이 문장은 남긴다.
그대로 두는 것	V2 투영기, 학습 문항 993, 3,000단계, 배치 4, lr(1e-4 / 3e-4 / 3e-4), 글 가리기 0.5, 백본 로더, 채점기(90cc93e4…). 기존 스크립트는 바꾸지 않고 새 판(학습·생성 각 1개)을 만들어 diff를 공개한다.
설계	{A, E} × λ_ift 0(보조 손실 없음, 대칭) × 시드 3(2047·2049·2050) = 학습 6개. 같은 decoder로 matched·shuffled·다른 시작점·평균·zero·no-injection 비교(NLL), matched·shuffled 정확도(생성).
데이터	학습 993, 평가 개발 600만. 새 test 데이터는 열지 않는다.
미리 정할 판단 기준	(1) 같은 학습 조건 A − E(matched z* 대 matched z_src)가 3시드 모두 같은 방향이고 3시드 합산 McNemar가 유의, (2) 같은 A decoder에서 matched − shuffled가 3시드 중 2개 이상에서 유의. 보고: 시드별·평균, strict·lenient, `\boxed` 비율, 형식을 지킨 답 안의 정답률, NLL, 생성 길이.
성공 조건 해석	두 기준을 모두 넘으면 S1 구조로 새 데이터 5차 확증을 검토한다. 넘지 못하면 S2(통로 용량)로 원인이 연결부인지 잠재 내용인지 가린다.
예상 비용	GPU 5·6·7에서 학습 약 3시간 + 평가 약 5~6시간, 총 9시간 안팎
위험	형식 지시가 순정 모델(C)의 정답률도 함께 올린다. 이는 의도된 것이다(공정 비교). 게이트 2·3의 크기는 줄어들 수 있다.

---

14. 결과 삼분류와 영향 (교수님 미팅용 · CTO 의견 CTS-435)

CTO 의견(10/14): 추가 실험 없이 유지할 결과, 폐기·재해석할 결과, CTS·System 1.5에 미치는 영향을 정리해 교수님과 논의한 뒤 "진단 연구로 마무리"와 "새 구조로 재시작" 중 하나를 먼저 결정한다. 전문: `shared/reports/TRIAGE-G2-results-20261014.md`.

14-1. 유지할 수 있는 결과

결과	근거
G1 정본 DEQ의 수렴·변별	신규 520 중 517 수렴, 최근접 일치 519/520, 평균 cos 0.569. 디코더와 무관한 역학계 성질
근본 원인 진단 1: 투영기 출력의 크기·상수 지배	칸당 norm 1,258~1,945(단어 50.5), 문항 고유 비율 2~4%
근본 원인 진단 2: 잠재가 공통 soft prompt로 붕괴	12 디코더에서 자기≈남≈평균 잠재; 문항 정보 통과량과 정확도 상관 −0.85
형식 혼입의 규명	strict ↔ `\boxed` 상관 0.94; 형식 지킨 답 안 정답률 A≈E≈B1(약 18%)
절차·방법론	사전등록 4건, 새 문항 id 전수 검사, 재개 규칙, 원시 출력 포인터. 다음 구조에 그대로 사용 가능

14-2. 폐기하거나 재해석해야 하는 결과

결과	재해석
G2v4 "기준 충족"	시드 2047에서 A 디코더가 잠재를 잘 무시해 형식을 지킨 결과. 수정형 시스템의 자체 기준 충족으로만 기록, 원래 GOAL의 G2 통과 아님
1~4차 게이트 2·3의 A − C 우위	C가 형식 지시 없이 `\boxed`를 거의 쓰지 않은 형식 효과. 같은 형식 지시를 주면 C(12.83%)가 모든 디코더(3.8~8.7%)보다 높음
M7 개발 NLL의 "A만 문항 특이성"	정확도로 옮겨지지 않았고 시드 의존적
G2 게이트 설계	strict·형식 지시 없음·shuffled 보조 설계는 잠재 기여를 재지 못함. lenient 주 지표, 형식 고정, matched−shuffled 주 게이트, 시드 반복으로 재설계 필요
"잠재에 정보가 충분하다"	문항마다 다르지만(지문) LM이 읽을 수 있는 내용은 거의 없음

14-3. 영향과 CC의 견해

- **핵심 가설("DEQ 반복이 문항별 유용 정보를 추가")은 증명되지 않았다.** 같은 형식 조건에서는 잠재 prefix 주입이 순정 모델보다 성능을 낮춘다.
- **영향:** Stage 1 DEQ 백본은 역학계로서 유효(G1)하나 "디코딩에 유용한 표현"이라는 용도는 미입증. 잠재→LM prefix 연결부(v3.6·V2)는 재사용 불가. z*의 내용에 기대는 하류 구성 요소가 있다면 전제 재검토. 평가 프로토콜은 형식 고정·lenient·shuffled 주 게이트·시드 ≥ 3·cluster bootstrap을 기본으로. (System 1.5 로드맵은 공유 문서에 없어 교수님·CTO 확인 필요.)
- **현재 구조에서 아직 확인할 가치가 있는 것:** 결정 뒤에 한다면 S2(오라클 잠재로 통로 용량 점검, 1~2일) 하나다. 연결부가 병목인지 DEQ 잠재의 내용이 병목인지 가르므로, "진단 연구로 마무리"와 "새 구조로 재시작" 사이의 결정을 데이터로 뒷받침한다. S1의 matched−shuffled +1.17%p(CI 하한 −0.17)는 시드를 더해 볼 수 있으나, 넘더라도 "잠재가 미약하게 읽힌다" 이상의 의미는 없다. 그 외(A 안정화, LoRA, S3, IFT)는 지금 자료로는 가치가 낮다.
- **종합:** 현재 구조로 G2를 통과시키려는 시도는 더 하지 않는 것이 맞다. 두 선택지의 비교는 전문 §6.

---

15. 결정 요청과 다음 단계

> **CTO 의견에 따른 진행 원칙 (10/12, CTS-432).** 1단계 {A, E} × {보조 손실 유/무} × 시드 3은 원인 분리용 개발·진단 실험으로 진행하며 설정을 바꾸지 않고 코드·체크포인트·원시 로그를 보존한다. 같은 디코더에서 matched z*·shuffled z*·matched z_src·평균 z·zero/no-injection을 비교한다. 다음 단계로 넘어가는 기준은 (1) 같은 학습 조건에서 matched z*가 matched z_src보다 일관되게 높고, (2) 같은 디코더에서 matched z*가 shuffled z*보다 유의하게 높은 것이다. 두 조건이 개발 데이터와 여러 시드에서 모두 확인될 때만 새 데이터 5차 확증을 검토하며, 그전에는 새 test 데이터를 열지 않는다. IFT 실험과 데이터 확대는 5차 이후로 둔다.

항목	내용	결정 주체

방향 결정 (CTS-435)	현재 구조를 진단 연구로 마무리할지, 새 구조로 다시 시작할지. CC 제안: 결정 전 S2(통로 용량 점검) 1회로 근거 보강 (14-3절)	교수님·CTO·Principal
CTS-431	개선판(M7) 통과를 GOAL의 G2 통과로 인정할지 → CTO 의견(CTS-432·435)에 따라 "수정형 시스템의 자체 기준 충족"으로 정리, 원래 G2는 미통과	정리됨
ESC-0009	서버 /home 100%(3.6T 중 shoon 892G, 다른 사용자 1.3T, 권한 밖 약 1.2T). 재현용 텐서가 휘발성 /tmp에 있음	Principal·서버 관리자
ESC-0007	GPU 2 하드웨어 오류, GPU 0/1/3 감속	Principal
권고 후속	λ_ift 대칭 재현(A·E 같은 보조 손실), 다중 시드, 정본 로더 통일, 문항 내용 기여(A–B1) 강화. 새 데이터 출처가 필요하다(현 5,000문항 풀은 미열람 문항이 남지 않음)	Principal 승인 후 CC

---

16. 탐색 X 계열 (10/19~10/23) — 연결부 수리와 잠재 내용 검증

사용자 결정(10/14·10/19)으로 교수님 미팅(10/28) 전까지 "진단 연구 마무리 vs 새 구조"를 데이터로 뒷받침하기 위한 탐색 실험을 진행했다. CTO께는 설계안을 보고서 13·16절로 공유했다. 모든 단계의 판단 규칙은 결과 전에 `shared/proposals/X_INTERFACE_PLAN_20261019.md`·`X8_READABLE_LATENT_DEQ_20261021.md`에 고정했다. 데이터는 학습 993·개발 600만 썼고 새 test 문항은 열지 않았다. 지표는 CTO 지침(CTS-434)대로 lenient 주 지표, `\boxed` 비율 선확인, 문항 단위 bootstrap 10,000회(seed 2026)·3시드 합산, **matched − shuffled(자기 잠재 − 남의 잠재) CI 하한 > 0**이 핵심이다. 대조 C-fmt(순정 Gemma + 형식 지시)는 lenient 15.67 %, strict 12.83 %, `\boxed` 35.5 %.

질문의 구조. S2(12-7절)에서 "정답 해설을 통째로 담은 오라클 잠재도 전달되지 않는다"가 나왔으므로, 먼저 **통로**(잠재 → LM)를 고치고(X1·X3·X5·X6), 통로가 열린 뒤에 **DEQ 잠재의 내용**을 묻는다(X7·X8-0·X8-A).

16-1. 단계별 결과 한눈에

단계	무엇을 바꿨나	잠재	matched − shuffled (lenient)	matched − C-fmt	사전 규칙 판정
S2 (10/14)	prefix 64칸 + 고정 LM	오라클	+0.61 [-0.78, +1.94]	-9.89	연결부 병목
X1 (10/19)	prefix + LM LoRA r16	오라클	+1.11 [-0.22, +2.44]	-7.61	여전히 막힘
X3-min rev2 (10/19)	중간 층 cross-attention 브리지, 순정 LM 고정	오라클	+2.50 [-0.50, +5.50]	-5.17	브리지 결함
X3 rev3 (a)/(b) (10/20)	글 가리기 0 / + 잠재 없음 0.3	오라클	+0.50 / +1.83 (CI 0 포함)	-6.33 / -2.67	불충족
D2 (10/20)	rev2 브리지를 학습 200문항에 적용	오라클	+9.50 [+2.50, +16.50]	-7.50 (순정 33.0 %)	읽기 경로가 자유 생성에서 미작동
X5 (10/20)	**표적을 모델 자신의 생성문으로, 정답 구간 가중 5**	**오라클**	**+3.50 [+0.50, +6.50]**	**0.00**	A 충족 · B 미달
X6-R (10/20)	**X5 재현, 시드 2049·2050 → 3시드 합산**	**오라클**	**+3.56 [+1.61, +5.50]**	**+0.06**	통로 부분 개방
X6-S (10/20)	답 가중 20·3,000단계 (강화)	오라클	+1.83 [-1.17, +4.83]	-3.00	해악 재발

X7 (10/21)	**X5 레시피로 A(z*′) vs E(z_src), 3시드**	**DEQ z*′ / z_src**	A -1.33 [-3.06, +0.33] / E -1.17	A -2.50	(1)·(2) 불충족
X8-0 (10/21)	문제 글 은닉 상태를 잠재로(오라클 구성, 해설 대신 문제)	문제 잠재	+0.17 [-1.50, +1.94]	-3.17	내용 없음
X8-A (10/23)	**DEQ(LoRA·routing·γ) + 브리지 공동 학습, 읽힘 손실, K_unroll 2, λ_fp 0.1**	**학습된 DEQ z_out**	+1.28 [-0.44, +3.00]	-0.83	(1)·(2) 불충족 · G1 잔차 유지

모든 값은 개발 600, 3시드 합산(단일 시드는 표기), 문항 단위 bootstrap 95 % CI. 전문: shared/reports/RESULT-X1-lora-prefix-20261019.md, RESULT-X3-xattn-20261019.md(§1~§9), RESULT-X5-stylematched-20261020.md(§6 정정 포함), RESULT-X6-replication-20261020.md, RESULT-X7-stageAE-20261021.md, RESULT-X8-0-problem-latent-20261022.md, RESULT-X8A-readable-deq-20261023.md.

16-2. 핵심 표 — 같은 기구·같은 레시피(X5)에서 잠재 출처별 전달

잠재의 출처	문제 글에 없는 정보	matched − shuffled (3시드 합산)	matched − C-fmt	읽는 것
정답 해설의 은닉 상태(오라클)	**있음(답)**	**+3.56 [+1.61, +5.50]**	**+0.06**	**전달됨 — 그러나 순정 대비 이득 0**
DEQ 고정점 z*′ (X7)	DEQ가 계산한 만큼	-1.33 [-3.06, +0.33]	-2.50	내용 없음
초기 잠재 z_src (X7)	없음	-1.17 [-2.89, +0.56]	-1.44	내용 없음
문제 글의 은닉 상태 (X8-0)	없음	+0.17 [-1.50, +1.94]	-3.17	내용 없음
읽히도록 학습한 DEQ z_out (X8-A)	DEQ가 계산한 만큼	+1.28 [-0.44, +3.00]	-0.83	방향만 개선, 유의하지 않음

> **읽은 것.** 통로는 **문제 글에 없는 정보**가 잠재에 들어 있을 때만 값을 낸다(오라클). 문제 글에서 계산된 잠재는 어떤 것도 — 기존 DEQ 고정점, 초기 잠재, 문제 은닉 상태, 읽히도록 다시 학습한 DEQ까지 — 개발 문항의 정답률을 올리지 못했다. 그리고 정답을 담은 잠재조차 순정 모델을 넘지 못한다(기구 비용 ≈ −3 %p를 내용이 겨우 상쇄). G2(A > E, A > C)는 "읽는 쪽"이 아니라 **"DEQ가 문제 글에 없는 답 관련 내용을 계산해 내는가"**의 문제이며, 현 설계 범위(1,500단계·펼침 2걸음·LoRA r8)에서는 그 답이 "아니오"다.

16-3. 과정에서 밝혀진 것

- **학습 해악의 정체(가설 → 지지).** 브리지를 정답 해설로 가르치면 모델이 짧은 해설 문체를 흉내 내 풀이를 일찍 끝내고 틀린다(순정은 완주한 문항에서 31.9 % 정답, 브리지 모델은 8~14 %). 표적을 모델 자신의 생성문으로 바꾸자(X5) matched가 순정과 같은 정답률·길이·완주율로 돌아왔다. 다만 X5는 정답 치환·가중·예산 절단(575문항)도 함께 바꿨으므로 "문체만의 효과"로 분리하지 않는다(코덱스 지적 수용).
- **잠재 없음 학습은 정규화가 아니다.** 잠재를 뺀 샘플은 브리지에 기울기를 주지 않아(코덱스 REPORT-C001 D1, 실제 (b) 크래시로 확인) 학습량만 줄인다. rev3 (b)의 해악 감소는 그 때문이다.
- **더 세게 가르치면 해악이 돌아온다.** 답 가중 20·3,000단계(X6-S)는 학습 표적을 암기(답 CE 0.11)했지만 개발에서 순정보다 3 %p 낮다.
- **학습 문항에서도 못 넘는다.** D2: 학습에 쓴 200문항에서 순정 33.0 % > 오라클 matched 25.5 % > shuffled 16.0 %.
- **잠재 읽기 신호는 teacher-forcing에서만 크다.** 모든 브리지에서 학습 NLL은 크게 내려가지만 자유 생성 정답률은 따라오지 않았다(S2·X1·X3·X7).

16-4. 설계·실행 기록

구성	내용
브리지	`g2v9_xattn.py` rev2(ef3fbd5e…): 층 10·20·30·40 출력에 hidden += tanh(gate)·O(Attn(Q(h), K(ž), V(ž))), 모든 위치, 게이트 0 초기화(초기 = 순정), ž = RMS(z − center), 브리지 파라미터만 학습(약 21M). rev1은 O와 게이트가 모두 0이라 기울기가 흐르지 않는 결함으로 300단계에서 정지·재시작.
X5 레시피	`g2v10_train.py` rev3(48b71ffb…): 표적 = 순정 C-fmt가 학습 993문항에 쓴 자기 생성문(`cc_x5base.sh`, 0c026ea2…), 마지막 `\boxed{}`를 정답으로 교체(없으면 추가), 정답 구간 가중 5(앞글·상자·뒷글 분리 토큰화로 구간 정확), 표적 길이 ≤ 480(평가 예산 512), 1,500단계·배치 4·lr 3e-4, 무결성 계수(중복·빈 행·누락·절단·건너뜀·기여 id)와 입력 SHA를 manifest에 기록.
X8-A	`g2v11_x8a_train.py`(208eb131…): 캐시 z*'에서 M2' 주입형 걸음 2회를 미분 가능하게 펼쳐 DEQ의 lora_A/B·routing_proj·gamma(3,980,801 가중치, M3와 동일 집합)와 브리지를 함께 학습, L = L_read + 0.1·L_fp. 평가 잠재 `g2v11_x8a_latents.py`. 학습 전 잔차 10^{-3} → 학습 후 0.032~0.036(10^{-2}, 사전 기준 안).
실행기	`cc_x1.sh~cc_x8a.sh`: 입력 SHA 출력, 셀프테스트, GPU 유휴 검사, rc 전파, 600행·고유 id 600·채점 라벨 검사 뒤에만 완료 표식, 런처 자기 SHA 출력(X7부터). GPU 5·6·7만, /tmp 산출, 삭제 0건.
데이터 경계	학습 993(`configs/s7_train_993.json` 3088a153…)·개발 600(`results_s7/p6_item_order.json` 6c76ddb7…)만. 새 test 0. 채점기 90cc93e4… 불변.

---

17. 보조 에이전트 교체와 독립 검토 (10/18~10/23)

AG(Antigravity) 역할 종료. AG는 10/18 CTO 중단 의견 기간에 CC 지시 없이 서버 실험(g2v8)을 돌리고 "모든 관문 통과"라고 보고했다. CC 감사(`shared/audits/AUDIT-AG-g2v8-20261019.md`): 대조군 E가 C와 비트 동일(게이트로 차단), A의 이득은 결론 cue 강제(형식 효과), 개발 앞 60문항으로 best 선택(누설), 오라클 76 %는 cross-attention이 아니라 해설 은닉 상태의 선형 복사. 결과는 사용 불가. 사용자 결정(10/20)으로 AG를 배제했다.

코덱스(GPT-6 Astra High) 채택. 회사 PC 로컬에서 저장소 루트 `AGENTS.md`(서버·GPU·삭제·git·자격 증명 금지, 데이터 경계, 채점기 불변, 판정 단어 금지)를 따르며 `handoff/codex/` INBOX/OUTBOX로 소통한다. 코덱스는 결과를 판정하지 않고 숫자·불일치·결함만 보고한다.

코덱스 과제	발견·결과	CC 조치
C001 X3-min 코드 검토	D1 잠재 없음 분기에 기울기 없음(→ 실제로 rev3 (b)가 같은 예외로 중단), D2 실행기 rc 미전파, D3 재개 혼합, D4 절단 미검출	트레이너 가드, latent_drop 폐기, rc·행수 검사, 절단 계수 반영
C002 X1 재계산	CC 통계 완전 재현. 로컬 재채점 예외(Windows)	원인 추적 → 아래
C003/C003b X5 트레이너 사전 검토	답 구간 토큰 경계, 절단 후 정답·EOS 소실, 512 예산 밖 정답, 중복·빈 행 계수 기준, 비유한 값 혼입, 길이 보장 등 11건	rev2·rev3로 실행 전 전부 반영
C004 X5 재계산	통계 완전 재현. 결과 문서의 두 표현("해악 소멸·길이 동일", "효과의 절반")이 과장	RESULT-X5 §6 정정 추가
로컬 채점 불일치 (44/12,600) 근본 원인	코덱스가 "재진입·핸들 오류"를 보고 → CC 추적: math-verify의 Windows 시간제한이 호출마다 자식 프로세스를 띄우다 실패해 **기호 동등성이 조용히 꺼진 채** 채점됨("버전 차이"라는 CC의 이전 설명은 오류)	래퍼 rev3(Windows에서만 시간제한 무효화, 채점기 불변) → 서버와 12,600 중 1 불일치
C005~C009 (X6·X7·X8-0·X8-A·X8-A 코드)	발행됨, 코덱스 측 사용 한도로 대기	미팅 전 수신 시 반영

> 코덱스 검토는 "독립 재계산"이며 "서버 채점의 독립 재검증"은 아니다(코덱스 스스로의 구분). 외부 사람의 검증은 여전히 없다.

---

18. 결론과 결정 요청 (10/28 미팅)

1. **G1은 유지된다.** DEQ 고정점은 안정적으로 수렴하고 문항마다 다르다(4절). X8-A에서 읽힘 손실로 학습해도 상대 잔차 10^{-2} 안에서 수렴했다.

2. **G2는 미통과이며, 원인이 확정됐다.** 잠재 → LM 통로는 확보·재현됐다(오라클 +3.56 %p, 3시드). 그 통로로 읽어도 문제 글에서 계산된 어떤 잠재도 개발 정답률을 올리지 못했다. 정답을 담은 잠재조차 순정 대비 이득이 0이다.
3. **남은 선택지**(교수님·CTO 결정): (가) 진단 연구로 마무리 — G1 + 16절의 연쇄(통로 확보, 잠재 내용 부재, 형식 혼입 규명)를 결과로 정리. (나) DEQ 재설계 — 입력(문제 글만 → 중간 풀이 상태 등)·목표(답 관련 내용을 계산하도록)·구조를 바꾸는 새 연구. 이는 "현 DEQ가 문제 글에 없는 정보를 만들 수 있는가"라는 열린 질문이며 현 설계의 연장이 아니다. (다) LM 밖 readout 헤드 — 잠재에서 답을 직접 뽑는 별도 모듈. 오라클에서만 의미가 있고, 현 DEQ 잠재에는 뽑을 내용이 없으므로 (나) 없이는 가치가 낮다.
4. **CC 권고 (10/28 갱신, 19·20절 반영):** 마지막 확인 실험 2-1에서 정본 DEQ 반복이 정답 단서를 더하지 않았으므로(형태 −4.5 %p, 크기 −2.3 %p), 사전 결정 규칙대로 **(가) 진단 연구로 마무리**를 권한다. 정리할 결과는 G1, 원인 다섯 겹의 규명, 통로 수리(오라클 +3.56 %p 재현), "현행 인코딩이 단서를 잃고 새 인코딩은 담는다"(ENC), "DEQ 반복은 어느 출발점에서도 정보를 더하지 않는다"(INFO-PROBE·2-1)이다. (나) 새 연구를 택한다면 새 인코딩을 출발점으로 DEQ를 "정보를 더하도록" 처음부터 학습하는 설계가 되며, 새 사전등록·새 데이터 출처 승인·CTO 설계 공유가 먼저다.

항목	내용	결정 주체
방향 결정	**(가) 진단 연구 마무리 / (나) DEQ 재설계 / (다) 외부 readout**	**교수님·CTO·Principal**
데이터	(나)로 가면 새 문항 출처 필요(현 5,000문항 풀은 미열람 문항이 남지 않음)	CTO·Principal
ESC-0009	서버 /home 21G·루트 12G 여유(10/23). /tmp의 X 계열 산출물(브리지·DEQ 상태·잠재)은 휘발성	Principal·서버 관리자
보조 에이전트	AG 종료, 코덱스 보조 연구원(로컬·읽기 전용)	정리됨(10/20)

부록 C. X 계열 검증 파일과 SHA-256

파일	SHA-256
`scripts/g2v9_xattn.py` (브리지 rev2)	`ef3fbd5ed5d227c5b765fc01b95bcd920d4433b005e32e3057dcb479f2d1457d`
`scripts/g2v10_train.py` (X5 트레이너 rev3)	`48b71ffb94263284f611a35ce4a58bc9fb7609d9b74c18fe31cc95c8c3afe48f`
`scripts/g2v9_gen.py` (생성)	`14e466006b9a29c4d30181c424f5e6fb9872c781d03c3313c71fc433f7c2f3b3`
`scripts/g2v11_x8a_train.py` (X8-A 트레이너)	`208eb131f97988c8 …(전체는 RESULT-X8A 참조)`
표적 `results_s7/p6r/g2v9x5base/gen_Ctrain.jsonl`	`0c026ea2d7e863d3035a7918cec23dd83206794db7ea2c092ed3aa97c62fad69`
오라클 잠재 `/tmp/cts_s2/oracle_latents.pt`	`568f84e615c9f97b164dcb016767e96927dc6b55452499cf1749d52baffc1429`
z*′ 학습/개발 · z_src 학습/개발	`005e622d… / d43613d6… · 340ef5c2… / 0da3748a…`
DEQ 백본 `m1_final_frozen.pt`	`f2119bbe5c0ad914ee00c34e9109674d15de07c5e028e288ab05b88dd448d1f9`
채점표 x1 · x3(1단계) · x3(전체) · x5 · x6 · x7 · x8_0 · x8a	`afe57647… · 4df3baf8… · 12efc7c5… · 014516b4… · dd8a0609… · a084f309… · cc23828e… · d01a1f34…`
런처 `cc_x5.sh` · `cc_x6.sh` · `cc_x7.sh` · `cc_x8_0.sh` · `cc_x8a.sh`	`1dad8f07… · 788a3351… · 76a68ebf… · d71b4594… · 4a5e4578…`
원자료 폴더	`shared/reports/{x1,x3b,x3c,x3d,x5base,x5,x6,x7,x8_0,x8a}/`, 코덱스 교환 `handoff/codex/{INBOX,OUTBOX}/`

---

19. v5 이후 (10/24~10/28) — 원인을 끝까지 좁히기

보고서 v5(10/25) 이후 같은 사전등록 규칙으로 실험을 이어 갔다. 실행은 CC, 독립 재계산·코드 검토는 코덱스, 서버 없는 CPU 숫자 검증은 AG가 맡았다. 모든 단계는 결과 전에 사전 명시를 깃허브(`heosanghun/CTS_file`, 비공개)에 게시한 뒤 실행했다. 데이터는 학습 993·개발 600만이며 새 test 문항은 열지 않았다.

19-1. 단계별 결과

실험	바꾼 것	핵심 수치 (개발 600, lenient, 3시드)	읽은 것
X8-B (10/25)	X8-A의 DEQ 학습 파라미터를 FP32로 (BF16에서 갱신이 멈춰 있던 결함 수정)	matched - shuffled +0.56 [-1.17, +2.28] · 순정 대비 -2.83	갱신은 살아났지만 효과 없음. 라우터가 19개 모듈 중 같은 3개만 선택
X8-D (10/25)	**오라클 메모를 잘 읽는 리더를 얼리고 DEQ만 학습**	순정 대비 **+3.11 [+0.50, +5.72]** · matched - shuffled +0.44 [-1.50, +2.50]	**처음으로 순정을 넘음. 그러나 남의 메모로도 똑같이 올라 문항별 내용과 무관한 이득**
D2 · 반복 진단 (10/25)	답 구간 NLL, 학습 후 DEQ를 32회 반복	문항 효과 학습 문항에서만, 개발 ≈ 0 · 학습 후 잔차 0.57 → 0.027(32회)	DEQ를 학습시키면 메모가 고정점에서 벗어나고 천천히만 돌아옴(G1과 G2의 충돌)
XC (10/26)	리더에 "맞는 메모와 틀린 메모를 구별하라" 대조 항 추가	matched - shuffled +0.06 [-1.72, +1.78]	학습 문항에서만 구별(1.3~1.6 nats), 개발에서는 0
정보 탐침 (10/26)	**메모 속에 답의 단서가 있는지 직접 판독**	**z*′** 정답 형태 **+0.007** · 문제 문장 단어 목록 **+0.088**	**메모에는 과목·숫자 개수 같은 문제 겉모습만 있고 답의 단서는 없음. z*′와 z_src는 구별되지 않음(DEQ 반복이 정보를 더하지 않음)**
X8-E (10/26)	DEQ에 "답의 성질을 맞혀라" 보조 숙제	학습 문항 69 % · 개발에서 X8-D 대비 ≤ +0.005	외우기만 함, 일반화 없음

ENC 1단계 r2 (10/27)	**AI가 문제를 읽는 순간의 층별 상태 8개를 메모 후보로 판독**	31층 후보: 정답 형태 +0.107(z_src 대비 +0.100) · 정답 크기 +0.158(+0.103) · 8/8 통과	**힌트는 메모를 만드는 첫 단계에서 사라지고 있었다. 새 메모 방식이면 힌트가 남는다**

전문: CTS_file/INBOX/20261025-0210-CC-x8a-rootcause/의 RESULT-X8B·X8D·D2·ITER-PROBE·CONTENT-PROBE·XC·INFO-PROBE·X8E, shared/reports/RESULT-ENC-STAGE1-r2-20261027.md. 서버 SSH가 10/26 09:3x~10/27 22:5x 끊겨(잦은 접속 의심) 그 사이 실험은 없었다.

19-2. 원인 사슬 (다섯 겹)

겹	문제	상태
1	엄격 채점이 실력 대신 답 상자 습관을 쟀다(상관 0.94)	해결 형식 문장 고정, lenient 주 지표
2	연결부가 메모를 25~40배 부풀려 문항 차이를 묻었다	해결 중간 층 cross-attention 브리지
3	정답 해설로 가르치면 말투를 흉내 내 풀이를 일찍 끝냈다	해결 자기 생성문 표적(오라클 +3.56, 3시드)
4	메모를 다는 장치 자체의 비용(약 −3 %p)	부분 해결 X8-D에서 순정 +3.11(문항 무관)
5	**메모에 답의 단서가 없다. 메모를 만드는 첫 단계(0벡터 64칸 방식)에서 사라지고, DEQ 반복은 더하지도 빼지도 않는다**	원인 확인 · 해법 탐색 중 **ENC 1단계: 새 메모는 단서를 담음 → 2-1에서 DEQ가 더하는지 확인**

---

20. 마지막 확인 실험 2-1 (10/27~28) — DEQ 반복이 힌트를 더하는가

ENC 1단계에서 "문제를 읽는 순간의 31층 상태"가 정답 단서를 담는다는 것을 확인했으므로, 그 메모에서 **정본 DEQ를 1,000걸음 반복**하고 반복 전후의 단서를 같은 판독기로 비교했다. 이 프로젝트의 핵심 주장("DEQ 반복 계산이 정보를 더한다")을 직접 묻는 실험이다. 학습은 없다. 사전 명시는 실행 전에 게시했고(38bfb49), 실행 중 서버 재부팅이 두 번(02:28, 04:33) 있어 25문항 조각 저장·이어하기로 완료했다. 판정 기준은 바뀌지 않았다.

점검	결과
무결성	메모의 문항별 토큰 해시가 ENC 1단계와 1,593/1,593 일치. 코덱스 검증기 통과(키·모양·유한값·주입 일치·체크포인트)
수렴 (전제 ≥ 90 %)	개발 566/600 = **94.3 %** (중앙값 잔차 0.0005), 학습 95.8 % — 충족

과제 (개발)	반복 전 메모 · 찍기 대비	반복 후 메모 · 찍기 대비	반복 후 − 반복 전 (1차)	반복 후 − 현행 z_src
정답 형태	+0.115	+0.070	-0.045 [-0.070, -0.020]	+0.063
정답 크기	+0.140	+0.118	-0.023 [-0.065, +0.020]	+0.063
(보고) 과목	+0.518	+0.495	-0.023 [-0.043, -0.003]	+0.210

> **판정(사전 규칙): DEQ 반복은 정답 힌트를 더하지 않는다.** 이 판독과 표본에서 반복에 의한 개선을 확인하지 못했고, 정답 형태는 오히려 4.5 %p 줄었다. 반복 후 메모가 현행 z_src보다 나은 것(+0.063)은 전부 출발 메모(인코딩)의 몫이다. 기존 z_src에서 출발했을 때도 반복 전후가 같았으므로, 두 출발점 모두에서 "반복 계산이 정보를 더하지 않는다"가 반복됐다. 결정 규칙대로 **현 구조(정본 DEQ)로 G2에 재도전할 근거는 없다.** 한계: 정본 DEQ는 z_src 분포에서 학습돼 새 메모는 분포 밖이고, 주입 벡터도 함께 바뀌었으며, 선형 판독 기준이다.

전문: shared/reports/RESULT-ENC-STAGE2-1-20261028.md, 원자료 shared/reports/enc21/, CTS_file 5d4f2a4.

부록 A. 검증 파일과 SHA-256

A-1. 사전등록·감사

파일	SHA-256
shared/prereg/PREREG_S7_G2v4.md (잠금본)	5923fef7e82afdd74b7c471e6f98da4d724ef9d04c20e782b1227fe1d7c5a2ce
PREREG_S7_G2v4 rev3 (B PASS 대상)	82f969788cf59d95aee06ee854a294599b273e2702fc1fcd6d10eb542ed01d80
PREREG_S7_G2v3_1.md (3차)	3d1a6ee0292b58fcab514ec2b71588dc78a277f6c464e61739ebb4ac96573daa
PREREG_S7_G2v2.md (2차)	4ea1d9663c3a029a382bd503a9628992b600992160cfbf3aef61d0b66d726e85
PREREG_S7_D_v3_8.md (1차)	58b4a7f35249769716dca6316ab84cdc22d6259c88bd94a385a60f8a3c9bcd8b
감사 파일	shared/audits/AUDIT-P011~P014_*.md

A-2. 4차 체크포인트·스크립트 (서버)

파일	SHA-256
results_s7/g2v2/decoder_M7A_v36.pt	46977c2db533888dc13a8defe21ac287b26bd7ff1e08bb83eb22a4ca4bb99670
results_s7/g2v2/decoder_M7E_v36.pt	d0c33599c9586d3ed131877a2439ee09d5d48804a0408965daaa0238705afd5a
results_s7/g2v4m7rep/deq_Ah.pt	b43de6b0eeb0a16a5f04762ac9c6a95979e504bc48f8b52249213490d6485cf7
results_s7/g2v4m7rep/deq_Eh.pt	7e9dc5feb1e563996e90cc825c3567e54caadb86f5a9a25ce03435df37be9788
scripts/g2v4_m4_pilot_train.py (학습)	f492da0f1c35a3088397d2fec1748e9b56ed82bc3b371fe33cc0846706092ab0
scripts/g2v4_proj_v2.py (V2 연결부)	7cabcef2e13bb524a6815add5198853f21e8437fd04d018a6cef2227161df47a
scripts/s7_eval_gate_p6_v36f.py (생성)	fd6c2d03e3ed18d1597950edc79a01af8331d192c9f84b821a5b5bcf3f71cfe1
scripts/g2v3_m3_eval_latents_v2.py (한 걸음 잠재)	73db9dafd33e49e963d48aad4797c6b0eb7856e5e8e847fbb3b8dc0e5109921b
scripts/cc_g2v4_confirm.sh (확증 실행본)	d74fd9a96dc246028c09adc31adc736c672d5dc7ec50b6c0533965af261ca9bb
cc_g2v4_confirm_resume1.sh (재개 1 최종)	9c905cef5e5410fa9c1feb951f62afb363b4a5633140b603cfb709c636ec4f87
g2v4_fresh_prep_r1.py · g2v4_proximity_r1.py	e8876570b4f20360f8e40a286ad73fff28531d983e35cae24c30df0e34ed133f · 0d602101af358fdb0cfe873032e972b686a297b0b3a2c82df7e0dea0d904f0e8
채점기 · 채점 스크립트	90cc93e4b76704b209291ac43999a3f829ac79f7234c60362f95bccadd12fa13 · 547e1d91aa998908a0c436198f9890be961f18d643efec2c43dd700d415587cd

A-3. 문항 목록

파일	SHA-256
configs/g2v4b_fresh.json (4차 1,758, 사용 완료)	6e68e34c510593fb017d7dab5296c60ac506ce28d1ddeb3701231a69f696ce80
샤드 0 · 1 · 2	f8f305a1… · c5a3ce59… · 63935a09…
configs/g2v2_fresh1000.json (3차 1,000, 사용 완료)	35683874284b371c6641e1280b92e6a69292a2dc5d89585158154a45b41cb3db
configs/s7_train_993.json (학습)	3088a153f1d7ffabf77423a9354cd97795b9dae2daa7f429255bacfd4293784c
results_s7/p6_item_order.json (개발 600)	6c76ddb7cc4a1ee901291eee76ed99763ec5ebfec202cb30ba17f9bcee487e7c

A-4. 4차 결과물

파일	SHA-256

g2v4fresh_merged/gate_table.json	ea120d95bebf842e08b74a65b43178466ab7149aa5b10a687ab0d5bff37930a4
p6_gen_A.jsonl	e2edee7395421bdec447f7a6c75f27ef88f5dc230bbd2736ac87d2f22638ed66
p6_gen_B1.jsonl	3fdab13810e24da6b5353ef235588c9aa9c5b3ff177448cbfb7ee0a5009873a8
p6_gen_C.jsonl	1b130c2ece04c37021a9191e567773e82875ef49f8f1dbeab833b26520147372
p6_gen_E1.jsonl	d16f4bb557522baf988a9a1cd77ec3db3b1a6dcda2d661986995efc7ce8db5b0
raw_s7/g2v4_fresh_score.log	2b11f68b390243d26aff27f7c409b08c03bde8f46f59be5f8e42b2c9bc44a8d8
개발 600 채점 dev_score.json	e890c3c2d6fcf5981a195b785925ae7e3963f700809b9bfa0b66411b83e4f695
3차 gate_table.json	71f6bc260318b16b2a65799d75650c5080c41e19ba9f3842ee37f6f6c4763b73

부록 B. 로그와 원시 출력 위치

내용	위치 (로컬 D:\AI\cts\ 기준)
4차 판정 문서	shared/reports/RESULT-G2v4-confirm.md
4차 채점표·채점 로그·마스터 로그(원본·재개)	shared/reports/g2v4fresh/ (gate_table.json·md, g2v4_fresh_score.log, cc_g2v4_confirm_master.log 3507a21e…, cts_g2v4_resume1_master.log e04f01ba…)
근본 원인 진단 전문과 원자료	shared/reports/DIAG-G2v4-rootcause-20261011.md, g2v4diag/, g2v4v2/, g2v4deqlr/, g2v4m7rep/, g2v4posctl/
개발 600 정확도	shared/reports/g2v4dev/ (dev_score.json·md, cc_g2v4_dev_m7.log)
새 문항 선택·id 검사·잠금 증거	scratch/cc_g2v4_select_outputs.txt, cc_g2v4_evidence.txt, cc_g2v4_idscan_posctl.txt, cc_g2v4_lock_evidence.txt
근접도 보고	scratch/cc_g2v4_proximity.txt
3차 결과	shared/reports/RESULT-G2v3-confirm.md, g2v3fresh/
1·2차 결과	RESULT-P6R-G2-main.md, RESULT-G2v2-dev.md, DIAG-P6R-local-20261008.md
진행 기록·가설·접속 기록	shared/STATE.md, shared/GRAPH.md(H-DEC-7 채택), shared/ssh_log.csv
핵심 결과 백업 요약	shared/reports/BACKUP_SUMMARY_20261011.md
서버 쪽 원본	/home/shoon/cts_e1_s5/results_s7/p6r/g2v4fresh_merged/, raw_s7/g2v4_*, 재현용 텐서 /tmp/cts_g2v4_shoon/(휘발성)

CTS 프로젝트 진행 보고서 v5.1 · 2026-10-28 · 작성 회사 PC Claude Code(CC). 숫자는 모두 원자료(JSON·로그·SHA)에서 옮겼고 CC가 핵심 p값을 따로 다시 계산했다. 이전판 v4.9(10/14)·v3(10/8)·v2는 같은 폴더에 백업으로 보존. X 계열 숫자는 shared/reports/x*/의 채점표에서 옮겼고 코덱스가 X1·X5 통계를 독립 재현했다.